Simulación

Eje Temático Nº 5

Simulación de
Sistemas Discretos

4to Nivel
Ingeniería en Sistemas de Información

Ing. Revilla, Sergio Andrés
Ing. Sofía Gaggi

Contenidos

1. Sistemas de colas 2
De dónde venimos 2
Por qué se forman colas 2
Elementos de un sistema de colas 3
Disciplina de cola 4
Configuraciones 5
2. Notación de Kendall 6
3. Medidas de desempeño 8
Medidas desde el punto de vista del cliente 8
Medidas desde el punto de vista del sistema 8
Medidas desde el punto de vista del recurso 8
Un ejemplo completo 9
4. Dos maneras de promediar 11
Cómo se calcula un promedio en el tiempo 12
Las tres funciones escalonadas 12
5. Ley de Little 14
Verificarla en el ejemplo 14
Referencias bibliográficas 16

1. SISTEMAS DE COLAS

DE DÓNDE VENIMOS

En el Eje 4 vimos cómo se traduce un modelo a la computadora y cómo funciona por dentro un simulador de eventos discretos: una agenda de eventos futuros, un reloj que salta de suceso en suceso y un ciclo que se repite hasta que se cumple la condición de corte. Sabemos, entonces, **cómo se ejecuta** un modelo.

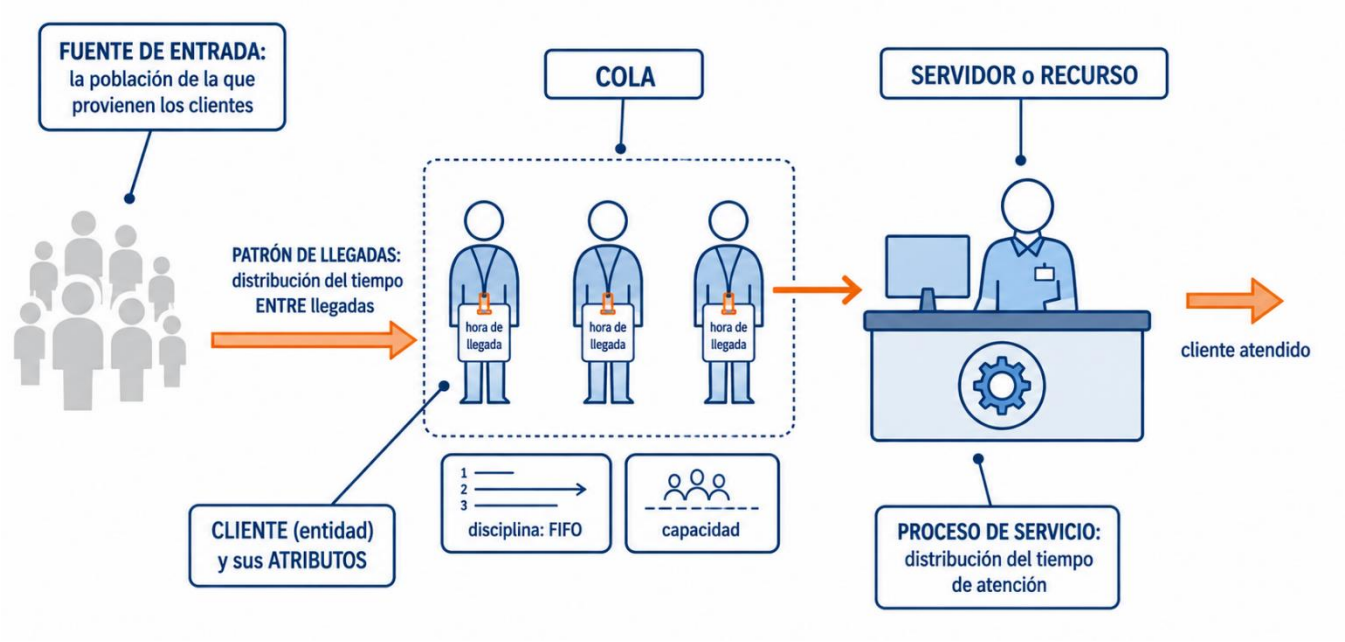
La enorme mayoría de los sistemas que se estudian con simulación de eventos discretos —una línea de producción, una guardia hospitalaria, un centro de distribución, un servidor web, una caja de supermercado— son **sistemas de colas**. Tienen entidades que llegan, recursos limitados que las atienden y esperas que se forman cuando la demanda supera momentáneamente a la capacidad. El vocabulario y las medidas de la teoría de colas son, en la práctica, el lenguaje con el que se leen los resultados de casi cualquier simulación discreta.

POR QUÉ SE FORMAN COLAS

Una **cola** es una línea de espera que aparece cuando un recurso compartido debe atender a más solicitudes de las que puede procesar en ese momento. El cliente pide servicio, el servidor está ocupado, y entonces espera.

Conviene desarmar un malentendido de entrada. Uno tiende a pensar que si un recurso tiene capacidad suficiente en promedio no debería formarse cola. Es falso. **Las colas se forman aunque la capacidad media alcance**, simplemente porque las llegadas y los servicios no están sincronizados: a veces llegan tres clientes juntos, a veces el servicio de uno se estira. Esa desincronización es la variabilidad, y es la razón de fondo por la que existen las colas y por la que hace falta simular.

ELEMENTOS DE UN SISTEMA DE COLAS



Elemento	Qué es	Qué hay que definir para modelarlo
Fuente de entrada	La población de la que provienen los clientes.	Si es infinita (lo habitual) o finita, cuando la cantidad de clientes potenciales es chica y las llegadas dependen de cuántos ya están en el sistema.
Cliente	La entidad que solicita servicio. Puede ser una persona, una pieza, un pedido, un paquete de datos.	Sus atributos: instante de llegada, tipo, prioridad.
Patrón de llegadas	Cómo se suceden las llegadas en el tiempo.	La distribución del **tiempo entre llegadas**, no el instante de llegada. Es la conexión directa con el Eje 3.
Cola	El espacio donde esperan los clientes que no pueden avanzar.	Su **capacidad** (infinita o finita) y su **disciplina**.
Servidor o recurso	Lo que presta el servicio.	Cuántos hay, si son idénticos, y la distribución del **tiempo de servicio**.
Proceso de servicio	Cómo se atiende.	Duración, cantidad de canales, disponibilidad, y si hay más de una estación en secuencia.

Aclaración: los patrones de llegada y de servicio se describen generalmente con una **distribución de probabilidad**, no con un valor fijo. Que el tiempo medio de atención sea de tres minutos no significa que cada atención dure tres minutos, y esa diferencia es precisamente la que genera las colas. Las distribuciones y los métodos para generar valores a partir de ellas son los del Eje 3.

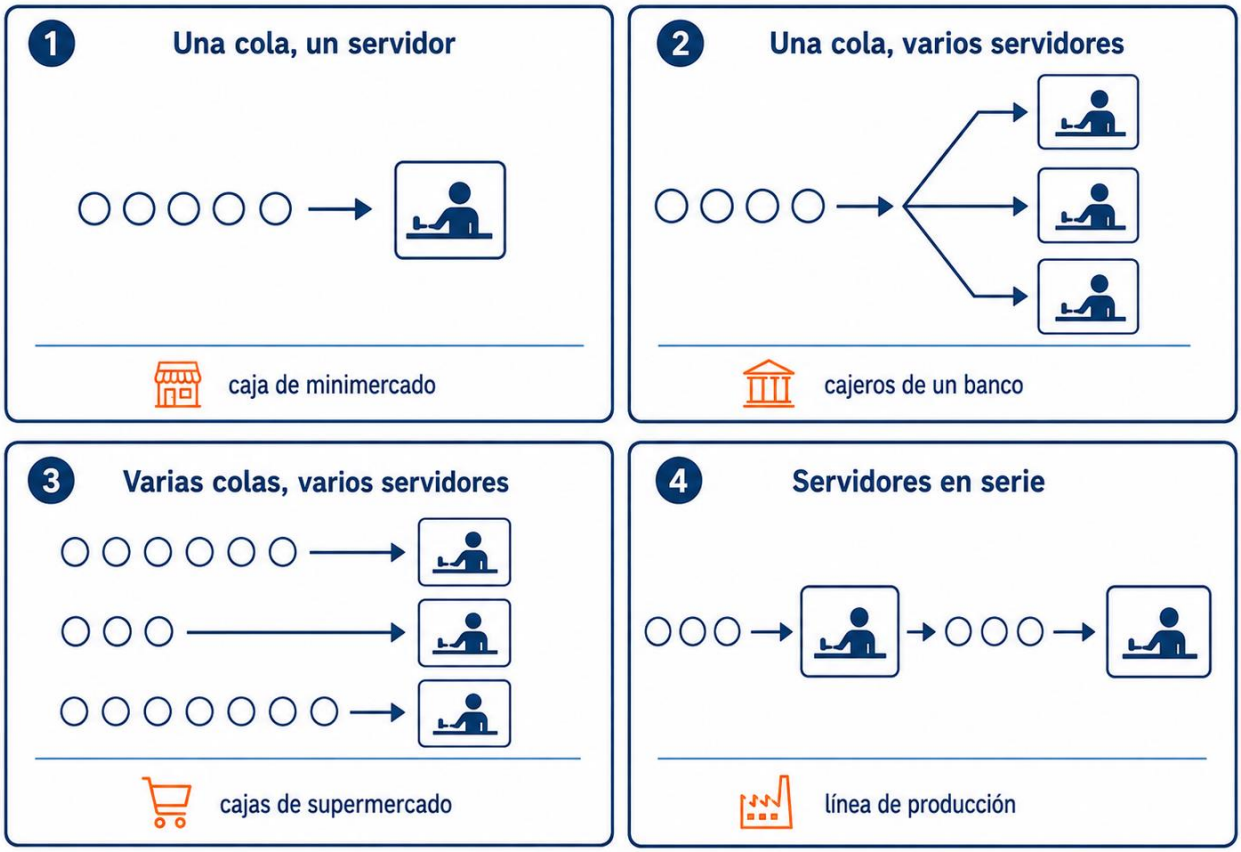
DISCIPLINA DE COLA

La **disciplina** es la regla que decide a quién le toca el turno cuando se libera un servidor. No cambia cuánto trabajo hay que hacer, pero **cambia quién espera y cuánto**, y por eso es una palanca de diseño barata: no requiere comprar capacidad.

Disciplina	Regla	Efecto sobre el sistema
FIFO / PEPS	Primero en llegar, primero en ser atendido.	La más común y la más percibida como justa. No optimiza nada, pero reparte la espera de manera pareja.
LIFO / UEPS	Último en llegar, primero en ser atendido.	Aparece de forma natural en pilas de material o en estanterías donde se toma lo de arriba. La espera media global no cambia, pero se vuelve mucho más desigual: algunos casi no esperan y otros muchísimo.
Aleatoria	Se elige al azar entre los que esperan.	Poco usada de forma deliberada; sirve como referencia teórica.
Por prioridad	Se atiende primero a cierta clase de clientes.	Mejora el nivel de servicio del grupo prioritario a costa del resto. La media global puede incluso empeorar. Es la disciplina de una guardia médica o de un sistema de tickets.
Por tiempo de servicio	Primero el trabajo más corto.	Reduce la espera media del conjunto, pero puede postergar indefinidamente a los trabajos largos.

Una aclaración importante para los modelos con prioridad: hay que definir si la prioridad es **expropiativa** —el cliente prioritario interrumpe un servicio en curso— o **no expropiativa** —espera a que termine el servicio actual y pasa adelante en la cola—. Son sistemas distintos y dan resultados distintos.

CONFIGURACIONES



La forma en que se organizan colas y servidores no es un dato del sistema: **es una decisión de diseño**, y suele ser una de las más rentables porque no siempre implica agregar recursos.

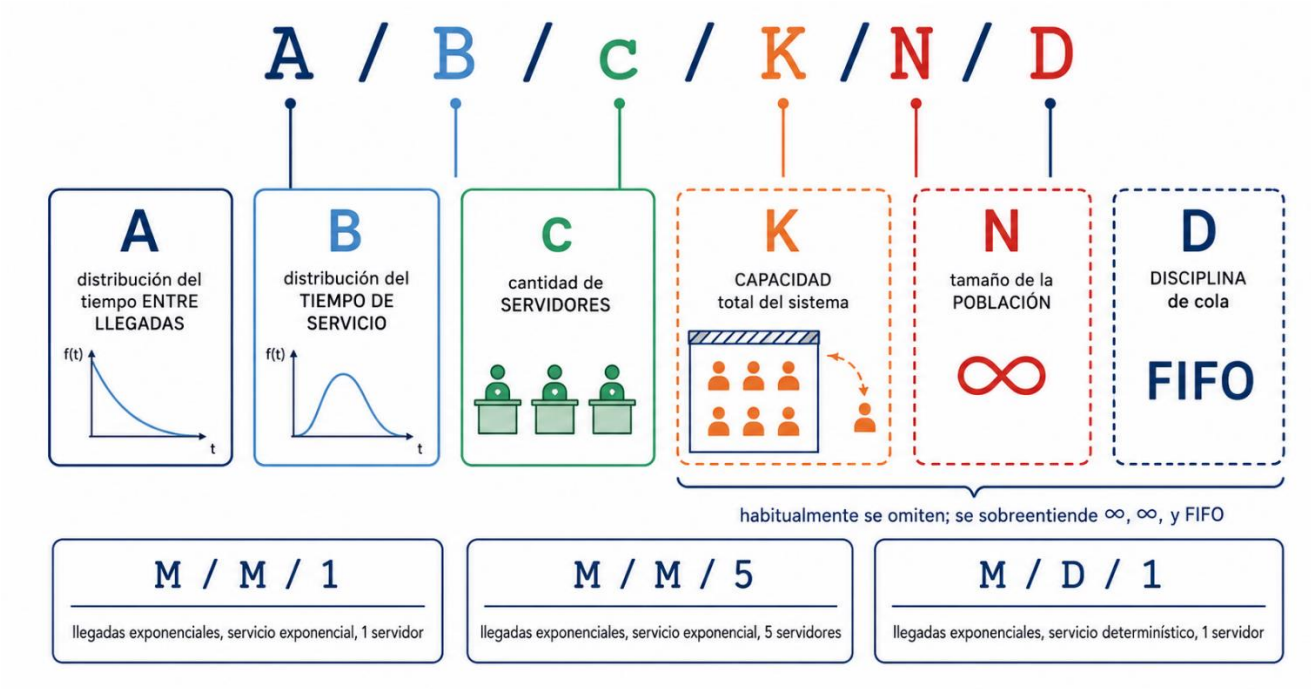
- **Una cola, un servidor.** El caso elemental, y el que usaremos para desarrollar los conceptos.
- **Una cola, varios servidores.** Una fila única que alimenta a todos los servidores, como en un banco. El cliente pasa al primero que se libera.
- **Varias colas, varios servidores.** Una fila por servidor, como en las cajas de un supermercado. El cliente elige fila al llegar.
- **Servidores en serie.** Varias estaciones que el cliente recorre en secuencia, cada una con su propia cola. Es la estructura típica de una línea de producción o de un trámite con varios pasos.

La comparación entre las dos configuraciones intermedias es el ejemplo clásico y vale la pena adelantarlo: **una cola única suele dar mejor resultado que varias colas paralelas** con la misma cantidad de servidores.

El motivo es que la cola única comparte la capacidad, y entonces nunca ocurre lo que sí ocurre con filas separadas: que un servidor quede ocioso mientras otro tiene gente esperando. Es una mejora que no cuesta dinero, solo reorganización.

2. NOTACIÓN DE KENDALL

Describir un sistema de colas en palabras es lento y ambiguo. La **notación de Kendall** lo hace en una línea, y es el estándar en toda la bibliografía y en la documentación de los simuladores.



Posición	Qué indica	Valores habituales
A	Distribución del tiempo **entre llegadas**	M (exponencial, «markoviana»), D (determinística), G (general, cualquiera)
B	Distribución del **tiempo de servicio**	M, D, G
c	Cantidad de **servidores** en paralelo	1, 2, 3, …
K	Capacidad **total** del sistema (cola más servicio)	Número, o ∞ si no hay límite
N	Tamaño de la **población**	Número, o ∞ si es ilimitada
D	Disciplina de cola	FIFO, LIFO, prioridad

En la práctica **casi siempre se escriben solo los tres primeros campos**. Cuando se omiten los últimos tres se sobreentiende que la capacidad y la población son infinitas y que la disciplina es FIFO. Así, M/M/1 significa: llegadas exponenciales, servicio exponencial, un servidor, sin límite de capacidad, población infinita y atención por orden de llegada.

Sistema real	Notación	Lectura
Una caja de minimercado, fila única sin límite	M/M/1	Un servidor, llegadas y servicios exponenciales
Cinco cajeros de un banco con fila única	M/M/5	Cinco servidores compartiendo una cola
Un centro de llamadas con 20 operadores y 30 líneas	M/M/20/30	Si las 30 líneas están ocupadas, la llamada se pierde
Una máquina con tiempo de ciclo fijo	M/D/1	El servicio no tiene variabilidad
Un taller con tiempos medidos que no siguen ninguna distribución conocida	G/G/1	El caso general: sin fórmula cerrada, se resuelve simulando

Por qué nos sirve: escribir la notación de Kendall de un sistema **obliga a explicitar los supuestos del modelo antes de construirlo**. Cuando alguien tiene que decidir si su sistema es M/M/2 o M/G/2/15, está tomando decisiones de modelado conceptual: qué distribuciones asume, cuántos recursos hay, si hay límite de capacidad. Es una herramienta de modelado disfrazada de notación.

3. MEDIDAS DE DESEMPEÑO

Un sistema de colas se evalúa con un conjunto acotado de indicadores, que se dividen en tres grupos según qué se está midiendo.

MEDIDAS DESDE EL PUNTO DE VISTA DEL CLIENTE

Miden **tiempo**, y se calculan promediando sobre los clientes que pasaron por el sistema.

Símbolo	Nombre	Cómo se calcula
W_q	Tiempo promedio de espera **en cola**	Suma de las esperas de todos los clientes, dividida por la cantidad de clientes
W	Tiempo promedio **en el sistema**	Suma de las permanencias (desde que llega hasta que se va), dividida por la cantidad de clientes

La relación entre ambas es directa: el tiempo en el sistema es la espera más el servicio. Si llamamos E_s al tiempo promedio de servicio:

$$W = W_q + E_s$$

MEDIDAS DESDE EL PUNTO DE VISTA DEL SISTEMA

Miden **cantidad de clientes**, y —esto es lo importante— se calculan promediando **a lo largo del tiempo**, no sobre los clientes.

Símbolo	Nombre	Cómo se calcula
L_q	Cantidad promedio de clientes **en cola**	Área bajo la curva de la longitud de cola, dividida por el tiempo total simulado
L	Cantidad promedio de clientes **en el sistema**	Área bajo la curva de la cantidad en el sistema, dividida por el tiempo total simulado

MEDIDAS DESDE EL PUNTO DE VISTA DEL RECURSO

Símbolo	Nombre	Cómo se calcula
ρ	Utilización del servidor	Tiempo que el servidor estuvo ocupado, dividido por el tiempo total simulado. Con c servidores, se promedia sobre los c.
—	Tiempo ocioso	El complemento del anterior: tiempo total menos tiempo ocupado
λ	Tasa de llegada	Cantidad de clientes que llegaron, dividida por el tiempo total

A estas se suman algunas medidas complementarias que suelen pedirse: la **longitud máxima de cola** (útil para dimensionar el espacio físico de espera), la **proporción de clientes que esperan** y, en sistemas con capacidad limitada, la **cantidad de clientes rechazados**.

UN EJEMPLO COMPLETO

Tomemos un puesto de atención con un solo servidor, disciplina FIFO, que arranca vacío. Los tiempos ya están dados —en este eje no los generamos—:

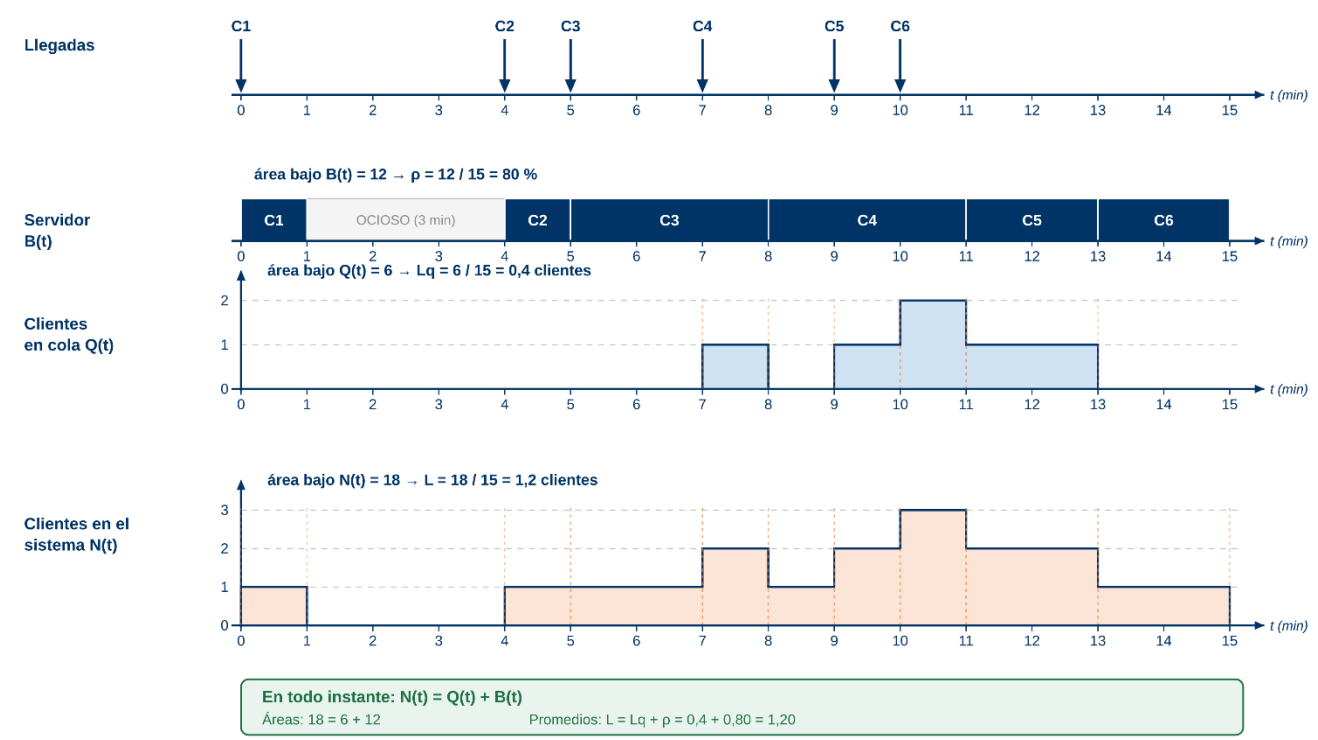
Cliente	Llegada	Duración del servicio
1	0	1
2	4	1
3	5	3
4	7	3
5	9	2
6	10	2

> **Atención al enunciado:** la segunda columna es el **instante** en que el cliente llega; la tercera es la **duración** del servicio, no el instante en que termina. Confundir instante con duración es el error más frecuente en este tipo de ejercicios y afecta a toda la tabla.

La regla que gobierna la tabla es una sola: **un cliente empieza a ser atendido en el mayor valor entre su instante de llegada y el instante en que terminó el cliente anterior**. Si llega y el servidor está libre, empieza enseguida; si no, espera.

Cliente	Llegada	Servicio	Inicio	Fin	Espera W_q	En sistema W
1	0	1	0	1	0	1
2	4	1	4	5	0	1
3	5	3	5	8	0	3
4	7	3	8	11	1	4
5	9	2	11	13	2	4
6	10	2	13	15	3	5
Total		**12**			**6**	**18**

Con la tabla completa, ya salen todos los indicadores. El horizonte simulado es T = 15, que es el instante en que se va el último cliente.



Indicador	Cálculo	Resultado
Espera promedio en cola, W_q	6 / 6 clientes	**1 minuto**
Tiempo promedio en el sistema, W	18 / 6 clientes	**3 minutos**
Utilización, ρ	12 ocupado / 15 total	**80 %**
Tiempo ocioso	15 − 12	**3 minutos**
Tasa de llegada, λ	6 clientes / 15	**0,4 clientes/min**
Longitud máxima de cola	Alcanzada en t = 10	**2 clientes**
Proporción que espera	3 de 6 clientes	**50 %**

Notá que el servidor estuvo **ocioso entre t = 1 y t = 4**: el primer cliente se fue y el segundo todavía no había llegado. Ese hueco es lo que hace que la utilización sea del 80 % y no del 100 %, y es una situación perfectamente normal: en un sistema real, un recurso que nunca descansa está saturado.

Faltan L_q y L, que se calculan de otra manera. Ese es el tema de la sección siguiente.

4. DOS MANERAS DE PROMEDIAR

Este es el concepto más importante del eje, y también el que más se confunde. **W_q y L_q no son la misma cosa ni se calculan igual**, aunque los dos parezcan «el promedio de la cola».



	Promedio por entidad	Promedio en el tiempo
Qué mide	Cuánto esperó cada cliente	Cuántos clientes había esperando
Sobre qué promedia	Sobre los **clientes**	Sobre el **tiempo**
Se divide por	La cantidad de clientes	El horizonte simulado
Unidad	Minutos	Clientes
Ejemplos	W_q, W	L_q, L, ρ

La consecuencia práctica es que **L_q no se obtiene promediando la longitud de la cola en unos cuantos instantes elegidos**. Eso daría un número distinto y sin sentido, porque le daría el mismo peso a un instante en que la cola tuvo dos clientes durante medio minuto que a otro en que tuvo un cliente durante ocho minutos.

CÓMO SE CALCULA UN PROMEDIO EN EL TIEMPO

La longitud de la cola no es un número: es una **función escalonada** que cambia a lo largo de la corrida. Sube cuando llega un cliente que debe esperar y baja cuando uno pasa a ser atendido. Si la llamamos Q(t), entonces:

$$L_q = \text{área bajo } Q(t) \div T$$

El área se calcula sumando rectángulos: se parte el horizonte en tramos donde la cola se mantiene constante y, en cada uno, se multiplica **cuántos había** por **cuánto duró el tramo**. Conviene armar los tramos con todos los instantes en que algo cambia: llegadas, inicios y fines de servicio. En el ejemplo de la sección anterior:

Tramo	Clientes en cola	Duración	Aporte al área
0 a 7	Ninguno	7	0
7 a 8	1 (el cliente 4)	1	**1**
8 a 9	Ninguno	1	0
9 a 10	1 (el cliente 5)	1	**1**
10 a 11	2 (los clientes 5 y 6)	1	**2**
11 a 13	1 (el cliente 6)	2	**2**
13 a 15	Ninguno	2	0
		Área total	**6**

Entonces **L_q = 6 / 15 = 0,4 clientes**. Ese es el promedio de la cola. Pero todavía falta L, que cuenta a los clientes que están **en el sistema**: los que esperan más el que está siendo atendido.

LAS TRES FUNCIONES ESCALONADAS

Un sistema de colas tiene en realidad **tres** funciones que cambian a lo largo de la corrida, y conviene no confundirlas:

B(t) vale 1 cuando el servidor está ocupado y 0 cuando está libre. Su área dividida por T da la **utilización ρ**.

Q(t) cuenta los clientes que **esperan** en la fila. Su área dividida por T da **L_q**.

N(t) cuenta los clientes que están **en el sistema**: los que esperan más el que está siendo atendido. Su área dividida por T da **L**.

En el gráfico de la sección anterior están las tres, una debajo de la otra y sobre el mismo eje de tiempo. Mirándolas juntas aparece una relación que se cumple en todo instante:

$$N(t) = Q(t) + B(t)$$

Dicho en palabras es evidente: **los que están en el sistema son los que esperan más el que está siendo atendido**. Y como vale instante a instante, vale también para las áreas y, por lo tanto, para los promedios:

$$L = Lq + \rho$$

En nuestro ejemplo el área bajo B(t) es 12, la de Q(t) es 6 y la de N(t) es 18 = 6 + 12. Dividiendo por T = 15: **L = 0,4 + 0,80 = 1,20 clientes**, exactamente lo que da medir el área de N(t).

Para qué sirve: esta relación ahorra trabajo y da un control. **Ahorra trabajo** porque, si ya calculaste L_q y ρ, no hace falta dibujar ni medir N(t): L sale de sumarlos. **Da un control** porque si medís las tres áreas por separado y la suma no cierra, hay un error en alguno de los tres gráficos.

Cómo leerlo: W_q = 1 minuto significa que **un cliente cualquiera esperó, en promedio, un minuto**. L_q = 0,4 clientes significa que **si uno mirara la cola en un momento al azar, encontraría en promedio 0,4 personas**. Son dos preguntas distintas sobre el mismo sistema: la primera le interesa al cliente, la segunda a quien tiene que dimensionar la sala de espera.

5. LEY DE LITTLE

Habrás notado algo en los números del ejemplo: el área bajo Q(t) dio 6, que es exactamente la suma de las esperas de los seis clientes. Y el área bajo N(t) dio 18, que es exactamente la suma de las permanencias. No es casualidad.

Cuando el sistema arranca vacío y termina vacío, **cada cliente aporta al área exactamente el tiempo que estuvo presente**. Sumar por clientes o integrar en el tiempo son dos formas de recorrer la misma superficie. De esa observación sale una de las relaciones más útiles del área:

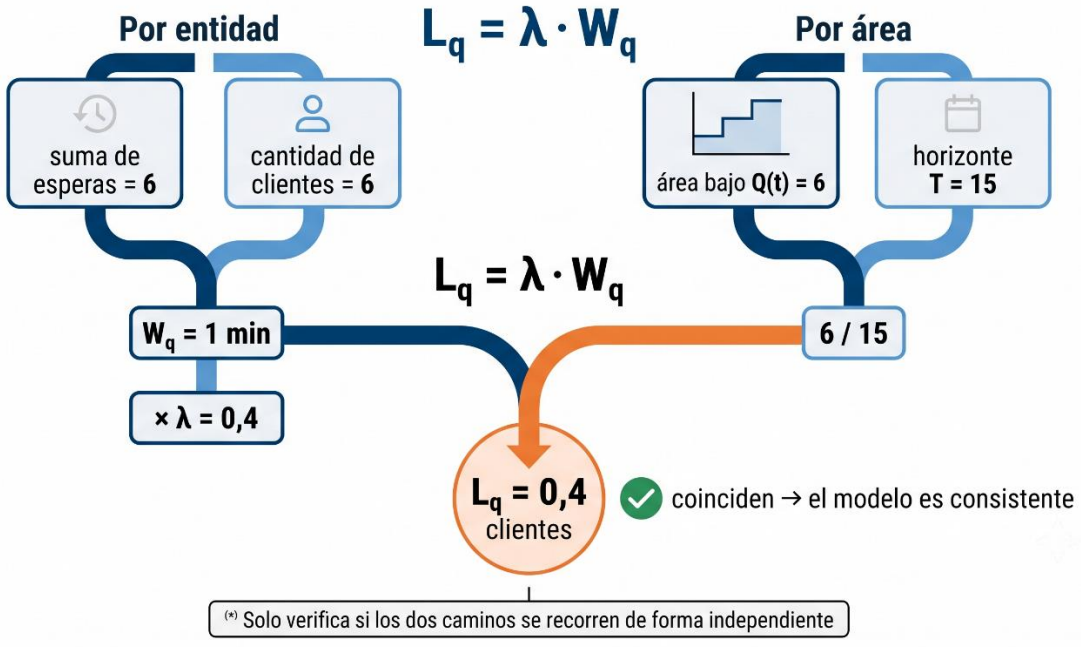
$$L = \lambda \cdot W \qquad L_q = \lambda \cdot W_q$$

La **Ley de Little** dice que la cantidad promedio de clientes en el sistema es igual a la tasa de llegada multiplicada por el tiempo promedio de permanencia. Y lo notable es su generalidad: **no supone ninguna distribución en particular, ninguna disciplina de cola ni ninguna cantidad de servidores**. Vale para cualquier sistema estable, lo que la vuelve aplicable a cualquier modelo que construyan.

VERIFICARLA EN EL EJEMPLO

Con $\lambda = 0{,}4$ clientes por minuto:

Relación	Por Ley de Little	Calculado por área	¿Coincide?
$L_q = \lambda \cdot W_q$	0,4 × 1 = **0,4**	6 / 15 = **0,4**	Sí
$L = \lambda \cdot W$	0,4 × 3 = **1,2**	18 / 15 = **1,2**	Sí



Advertencia metodológica: para que esto sea una **verificación** de verdad, los dos lados tienen que calcularse por caminos independientes: uno promediando esperas sobre clientes y el otro sumando rectángulos bajo la curva. Si L_q se obtiene dividiendo la suma de esperas por T, la igualdad se cumple siempre por pura álgebra y no comprueba nada. La utilidad está en llegar al mismo número por dos rutas distintas.

Y ahí está el valor práctico. En el Eje 4 dijimos que **verificar** es comprobar que el modelo está bien construido, pero no teníamos todavía ninguna técnica concreta. Esta es la primera: si en un modelo de simulación los indicadores no cumplen la Ley de Little, hay un error en el modelo o en la forma de recolectar los estadísticos. Es un control que se puede aplicar a cualquier modelo, incluido el del Trabajo Práctico Integrador.

REFERENCIAS BIBLIOGRÁFICAS

- COSS BU, Raúl. Simulación: un enfoque práctico. Limusa, 1992.
- SHANNON, Robert E. Simulación de sistemas: diseño, desarrollo e implementación. Trillas, 1998.
- LAW, Averill M. Simulation Modeling and Analysis. 6.ª ed. McGraw-Hill, 2024. (Ejemplo introductorio de la cola de un servidor; medidas de desempeño; sistemas de colas.)
- BANKS, Jerry; CARSON, John S.; NELSON, Barry L.; NICOL, David M. Discrete-Event System Simulation. 5.ª ed. Prentice Hall, 2010. (Modelos de colas y ejemplos de simulación manual.)
- ROBINSON, Stewart. Simulation: The Practice of Model Development and Use. 3.ª ed. Bloomsbury, 2025.
- HILLIER, Frederick S.; LIEBERMAN, Gerald J. Introduction to Operations Research. McGraw-Hill. (Capítulo de teoría de colas.)
- MARMOLEJO, Isaías Simón; ORTIZ DOMÍNGUEZ, Manuel. Un primer paso a la simulación con FlexSim. 2.ª ed. Flexin Iberia, 2019.