Simulación

Eje Temático Nº 6

Análisis de Datos
e Implantación

4to Nivel
Ingeniería en Sistemas de Información

Ing. Revilla, Sergio Andrés
Ing. Sofía Gaggi

Contenidos

Flujo general del proceso: 3
1. Datos de entrada 4
¿Qué datos conviene medir? 5
¿Cómo obtener los datos? 5
Preparación de la muestra 6
Outliers y datos faltantes 6
2. Estadística descriptiva 7
2.1 Tipos de Distribuciones 9
3. ¿Qué es la bondad de ajuste? 13
3.1. Prueba de bondad de ajuste K-S: Kolmogorov-Smirnov 15
3.2. Prueba de bondad de ajuste Chi-Cuadrado 16
3.3. ¿Cómo se elige la distribución? 16
3.4. Cómo se trabaja esto en FlexSim 22
4. Planeación Táctica 25
4.1. El problema de la variabilidad 25
4.2. Condiciones iniciales y de equilibrio 26
4.3. Determinación del tamaño de la muestra y réplicas 27
4.4. Reducción de varianza y comparación de alternativas 30
5. Validación y Análisis 32
5.1. Validación del modelo 33
5.2. Métodos subjetivos y métodos objetivos 34
5.3. Pruebas de hipótesis aplicadas a resultados 34
5.4. Validación de la estructura interna 35
5.5. Pruebas de campo 36

5.6. Análisis de sensibilidad 36
6. Implantación 39
6.1. Plan de implantación de una mejora 40
6.2. Piloto: experimentar en el sistema real con cuidado 41
6.3. Seguimiento y evaluación posterior 41
6.4. Comunicación de resultados 42
Referencias bibliográficas del Eje Temático 6 44

En las unidades anteriores se estudió cómo generar números pseudoaleatorios y cómo probarlos estadísticamente. Ahora el problema cambia: ya no buscamos números "al azar" para el generador, sino datos reales del sistema que queremos simular. El foco pasa a estar en qué medir, cómo limpiar esos datos y qué distribución representa mejor el proceso.

En simulación discreta, la calidad del modelo depende en gran medida de los datos de entrada. Si los tiempos de llegada o de servicio están mal medidos, el modelo puede estar bien armado y aun así dar resultados poco confiables. Por eso este capítulo trabaja la etapa previa a correr la simulación: el modelado de entradas.

En la práctica: Cuando FlexSim ajusta una distribución, en realidad está ayudando a traducir una muestra de datos en una función probabilística usable dentro del modelo.

FLUJO GENERAL DEL PROCESO:

El procedimiento práctico puede pensarse como una secuencia bastante simple. Primero se identifica qué variable del sistema conviene medir. Después se recolectan observaciones, se depuran errores y se resume la información con medidas descriptivas. A partir de allí se grafican los datos y se prueban distribuciones candidatas.

El paso final consiste en elegir una distribución que represente razonablemente bien el comportamiento observado y usarla como entrada del modelo. En FlexSim esto suele hacerse con el módulo de ajuste de distribuciones, donde se comparan varias opciones y se revisan sus indicadores de ajuste.

- Sistema real: la fuente de los datos.
- Recolección: observación, registros, sensores o planillas.
- Preparación: limpieza, orden y depuración.
- Análisis: medidas descriptivas y gráficos.
- Ajuste: comparación con distribuciones candidatas.
- Decisión: selección de la distribución para FlexSim.



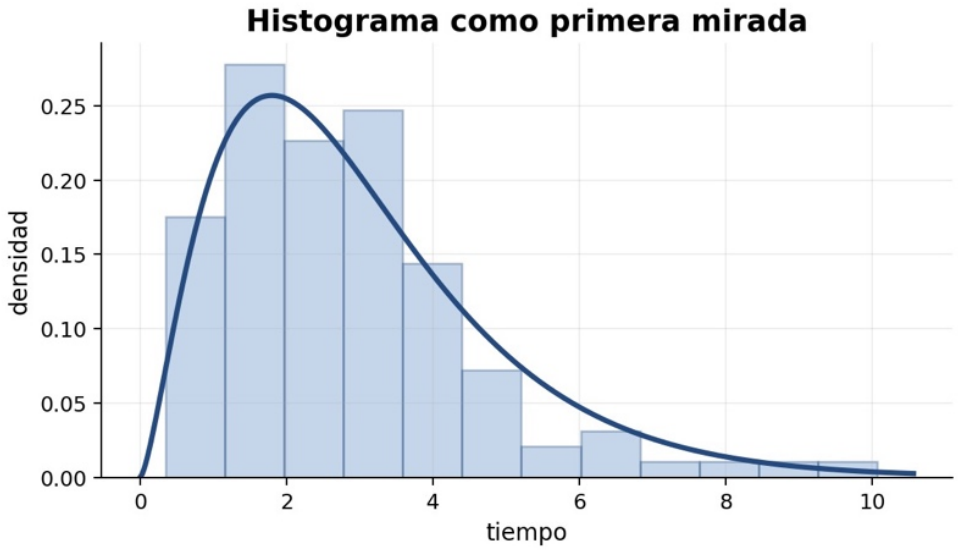
1. DATOS DE ENTRADA

¿Por qué importan tanto los datos de entrada?

La simulación no reemplaza la realidad; la aproxima. Por eso la pregunta correcta no es solo "¿el modelo corre?" sino "¿el modelo representa al sistema?". Esta es una de las razones por las que la etapa de análisis de datos es tan importante.

Por ejemplo, creer que si el tiempo medio de atención es de 5 minutos, entonces todas las atenciones pueden cargarse como 5 minutos fijos. En simulación, esa simplificación suele ocultar la variabilidad que generan las colas.

Dos sistemas pueden tener el mismo promedio de atención y, sin embargo, comportarse de forma muy distinta si uno tiene poca variabilidad y el otro mucha. Un promedio solo no alcanza: la dispersión y la forma de la distribución también afectan la cantidad de colas, la utilización de recursos y los tiempos de espera.



¿QUÉ DATOS CONVIENE MEDIR?

No todo dato del sistema es relevante para la simulación. **Conviene medir las variables aleatorias que realmente afectan el comportamiento del proceso.** En una caja, por ejemplo, interesan los tiempos entre llegadas, los tiempos de atención y, a veces, la cantidad de productos. El nombre del cliente, en cambio, no aporta al modelo.

- Tiempos entre llegadas.
- Tiempos de servicio o atención.
- Tiempos de traslado o espera.
- Cantidades de piezas, pedidos o clientes.
- Tiempos de falla y reparación.

La regla práctica es simple: medir lo que cambia la congestión, la ocupación de recursos o la capacidad de respuesta. Cuando una variable no modifica esas decisiones, probablemente no vale la pena cargarla en el modelo.

¿CÓMO OBTENER LOS DATOS?

Las fuentes más habituales son la observación directa, cronometraje manual, sensores, registros de un ERP, planillas Excel o logs de un sistema. La elección depende del proceso y del nivel de detalle que se necesite. Cuando los datos ya existen en el sistema, conviene aprovecharlos; cuando no, se puede medir por muestreo.

- Observación directa con cronómetro y planilla.
- Extracción desde bases de datos o sistemas existentes.
- Lectura de logs o historiales del proceso.
- Sensores, lectores o dispositivos automáticos.
- Entrevistas cuando no hay registro formal, aunque luego conviene validarlas con observación.

Lo importante es que la muestra represente bien al sistema
No alcanza con medir diez casos "cómodos". Hay que tomar datos de distintos momentos, días y condiciones, porque la variabilidad del proceso también forma parte del problema.

PREPARACIÓN DE LA MUESTRA

Antes de analizar, los datos deben ordenarse:

- Unificar unidades: segundos, minutos u horas.
- Eliminar registros duplicados o mal cargados.
- Revisar valores imposibles o incoherentes (ej: tiempos negativos).
- Separar por tipo de cliente, producto o trámite cuando corresponda.
- Ordenar la muestra de menor a mayor para analizarla mejor.

OUTLIERS Y DATOS FALTANTES

Un outlier es un dato muy alejado del resto. No siempre debe eliminarse: a veces es un error, pero otras veces es justamente un caso real que conviene conservar. Por ejemplo, en una caja puede haber un cliente excepcionalmente lento por un problema con el pago. Eso forma parte del proceso y puede ser relevante.

Los datos faltantes también deben revisarse. Si faltan pocos y no afectan la muestra, puede ser suficiente descartarlos. Si faltan muchos, puede ser necesario volver a medir. La decisión no debe ser automática: hay que entender por qué falta la información.

Un gráfico de caja y bigotes (boxplot) se usa para ver rápidamente cómo están distribuidos los datos y detectar posibles valores atípicos (outliers).

- La caja: contiene el 50 % central de los datos, entre el primer cuartil (Q1) y el tercer cuartil (Q3).
- La línea dentro de la caja: es la mediana, el valor central de los datos.
- Los bigotes: Los bigotes llegan hasta el dato más extremo que aún queda dentro de los límites. Para identificar el límite se calcula el rango intercuartílico: RIC = Q3 - Q1 Lím. inferior: Q1 - 1,5 x RIC Lím. superior: Q3 + 1,5 x RIC
- Los puntos fuera de los bigotes: son posibles valores atípicos u outliers.

2. ESTADÍSTICA DESCRIPTIVA

Una vez preparados los datos, conviene resumirlos con medidas descriptivas. Estas medidas no reemplazan al gráfico, pero ayudan a entender el centro de la muestra y su dispersión. En simulación, su función es orientar el ajuste de la distribución y detectar comportamientos raros.

Fórmulas básicas (para una muestra de n datos $x_1, x_2, \ldots, x_n$)

Medida	Fórmula	Cómo leerla
Media	$\bar{x} = (x_1 + x_2 + \ldots + x_n) / n$	Promedio de todos los datos. Resume el centro de la muestra en un solo número, aunque puede verse afectada por valores extremos.
Mediana	Dato central al ordenar la muestra; si n es par, promedio de los dos centrales	Es el valor que queda en el medio cuando los datos se ordenan. La mediana es más robusta que la media cuando existen outliers. Si la media y la mediana son parecidas, la distrubición suele ser más simétrica.
Moda	Valor que se repite más veces.	Puede no existir o haber más de una. Es útil cuando interesa saber qué valor aparece con mayor frecuencia en la práctica.
Varianza muestral	$s^2 = \Sigma(x_i - \bar{x})^2 / (n - 1)$	Mide cuánto se alejan los datos de la media. (Dispersión cuadrática)
Desvío estándar	$s = \sqrt{s^2}$	Medida de la dispersión, en la misma unidad que el dato. La varianza y el desvío miden cuán dispersos están los datos alrededor de la media. Ayuda a distinguir procesos estables, de procesos muy variables, aunque tengan la misma media.
Rango	máximo − mínimo	Amplitud total observada.
Coeficiente de variación	$CV = s / \bar{x} * 100$	Permite comparar dispersión relativa si $\bar{x} > 0$.

Ejemplo: datos 4, 5, 5, 6, 8. Media = 5,6; mediana = 5; moda = 5; varianza muestral = 2,30; desvío = 1,52. CV = 1,52 / 5,6 *100 = 27%

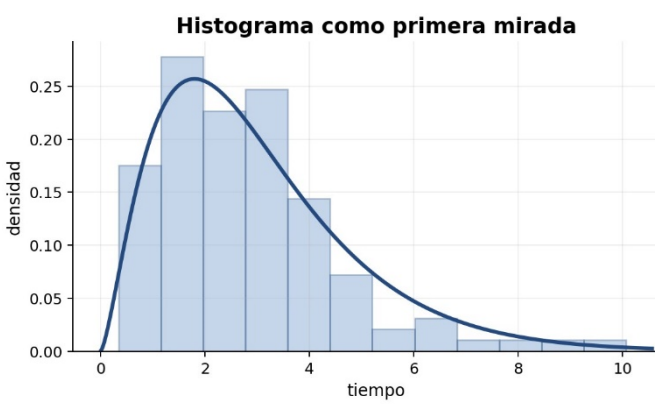
La media queda un poco por encima de la mediana porque el 8 empuja el promedio hacia arriba.

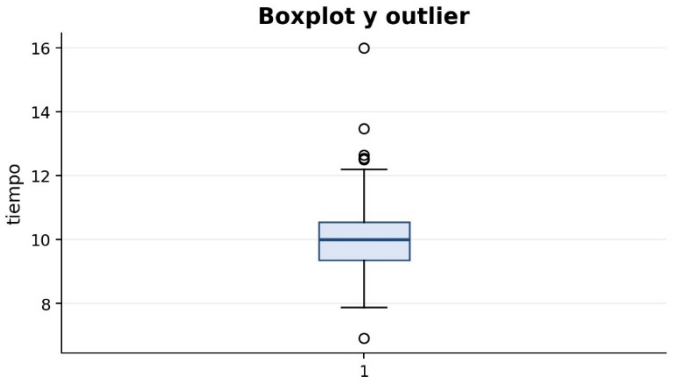
HISTOGRAMAS Y BOXPLOTS

El **histograma** es la primera mirada que conviene hacer sobre una muestra. Permite ver la forma general de los datos: si se concentran en un rango, si se inclinan hacia la derecha, si son simétricos o si tienen varios picos. En la práctica se colocan los tiempos obtenidos en un gráfico para ver qué forma toman. Después se compara su forma con distribuciones candidatas. Esta es la manera más rápida de tener una primera hipótesis.

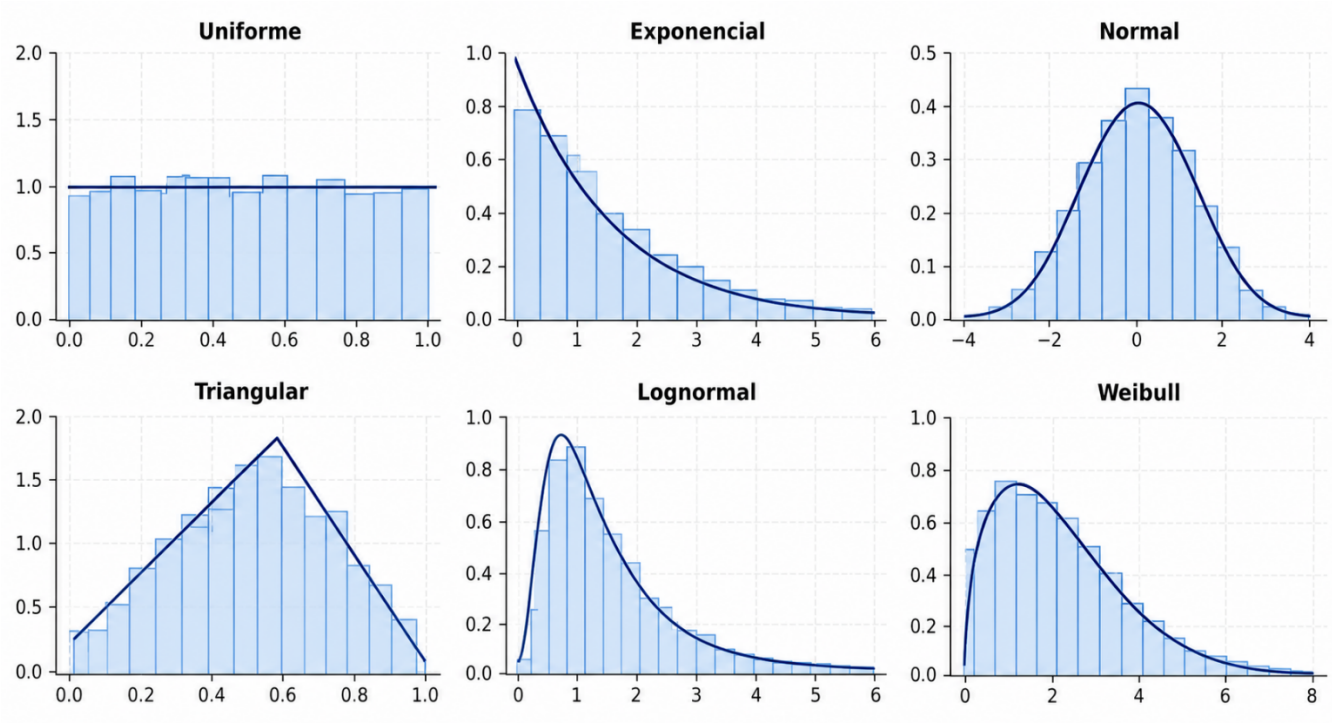
El **boxplot** complementa esa lectura porque muestra mediana, cuartiles y posibles valores atípicos.

Aun así, el gráfico solo orienta. La decisión final no debe tomarse mirando un dibujo: también **hay que revisar medidas descriptivas y pruebas de bondad de ajuste**. El gráfico dice "parece", la prueba dice "qué tan bien ajusta".





2.1 TIPOS DE DISTRIBUCIONES



Cómo leer el gráfico: eje X = posible valor del tiempo o cantidad; eje Y = densidad (qué tan frecuente es cada zona).

DISTRIBUCIÓN UNIFORME

Se usa cuando todos los valores dentro de un rango tienen la misma probabilidad aproximada.

Es una distribución simple, útil cuando se conoce un mínimo y un máximo, pero no hay datos suficientes para algo más fino.

Ejemplo típico: la reposición de una góndola tarda entre 2 y 4 minutos y no hay datos que indiquen que un valor sea más frecuente que otro.

Parámetros y estimación: a es el límite inferior y b el límite superior. Si esos límites vienen del proceso, se usa U(a,b). Si solo se dispone de una muestra, pueden tomarse como referencia el mínimo y el máximo, pero conviene verificar que no sean valores atípicos.

Media = $(a + b) / 2$ | Varianza = $(b - a)^2 / 12$

DISTRIBUCIÓN EXPONENCIAL

La curva alta cerca de 0 significa **muchos intervalos cortos**; la cola hacia la derecha representa **algunos intervalos largos**.

Aparece mucho en tiempos entre llegadas o en variables donde hay muchos valores pequeños y pocos grandes. En colas, suele ser una candidata natural para modelar arribos. Su forma cae rápido hacia la derecha y los valores grandes son cada vez menos frecuentes.

Ejemplo típico: tiempo entre clientes que llegan a una caja o entre consultas a un sistema. Entre que entra un cliente y entra el siguiente pueden pasar 30 segundos, 2 minutos o más; los intervalos cortos suelen ser más comunes.

Parámetro y estimación: λ (lambda) es la tasa de ocurrencia. Se estima con el inverso de la media muestral: $\lambda \approx 1 / \bar{x}$. La media de la exponencial es $1 / \lambda$. Por ejemplo, si el tiempo medio entre llegadas es 3,31 minutos, $\lambda \approx 0{,}302$ minutos^{-1}.

$F(x) = 1 - e^{(-\lambda x)}$ | Media $= 1 / \lambda$ | $\lambda \approx 1 / \bar{x}$

DISTRIBUCIÓN DE POISSON - DISCRETA

Es una distribución discreta, por lo que solo toma valores enteros: 0, 1, 2, 3, etc. Se representa con un gráfico de barras

Se utiliza para modelar la cantidad de veces que ocurre un evento durante un intervalo fijo de tiempo, espacio o longitud, cuando los eventos ocurren de manera independiente y con una tasa aproximadamente constante.

Ejemplo típico: cantidad de clientes que llegan a una caja en 10 minutos. Pueden llegar 0, 1, 2, 3 o más clientes, pero nunca 2,5 clientes.

Está relacionada con la exponencial: si el tiempo entre llegadas es exponencial con tasa λ, la cantidad de llegadas durante un intervalo de duración t sigue una distribución de Poisson con media λt. Son dos formas de observar el mismo proceso: la exponencial mide cuánto tiempo pasa entre llegadas y la Poisson cuántas llegadas ocurren.

Parámetro y estimación: λ (lambda) es la cantidad media de eventos por unidad de tiempo. Se estima dividiendo la cantidad total de eventos por el tiempo total observado. Por ejemplo, si llegan en promedio 0,302 clientes por minuto, en 10 minutos se esperan 0,302 x 10 = 3,02 clientes.

$$P(X = x) = \frac{e^{-\lambda t}(\lambda t)^x}{x!} \quad | \quad \text{Media} = \lambda t \quad | \quad \text{Varianza} = \lambda t$$

DISTRIBUCIÓN NORMAL

El centro de la campana es el valor más frecuente y los extremos son menos comunes.

Es la famosa campana. Se usa cuando los valores se agrupan alrededor de un centro y la dispersión es aproximadamente simétrica. La media, la mediana y la moda tienden a coincidir o a quedar muy cerca. La curva es equilibrada a ambos lados.

Ejemplo típico: el peso de paquetes de un mismo producto, centrado alrededor de un valor objetivo.

Parámetros y estimación: μ (mu) se estima con la media muestral x̄ y σ (sigma) con el desvío estándar muestral s. En una normal, la media indica el centro y σ indica cuánto se dispersan los datos. Para tiempos, se debe revisar que la probabilidad de valores negativos sea despreciable.

$\mu \approx \bar{x}$ | $\sigma \approx s$ | Varianza = s^2 | $z = \frac{x-\mu}{\sigma}$

DISTRIBUCIÓN TRIANGULAR

Se usa cuando se conoce un mínimo, un máximo y un valor más probable. Es muy práctica en estudios preliminares cuando no hay una muestra extensa. La forma es un triángulo: sube hasta el valor más probable (moda) y luego baja hasta el máximo.

Ejemplo típico: Un supervisor estima que un cambio de turno dura como mínimo 4 min, normalmente 6 min y como máximo 10 min.

Parámetros y estimación: a es el mínimo, m la moda o valor más probable y b el máximo. Se escriben como Triangular(a,m,b). Cuando hay pocos datos, estos tres valores pueden obtenerse de un experto; con muchos datos, se estiman a partir de los extremos y del pico del histograma.

Media = (a + m + b) / 3 | Varianza = ($a^2 + m^2 + b^2 - am - ab - mb$) / 18

DISTRIBUCIÓN LOGNORMAL

La curva tiene un sesgo positivo: muchos valores moderados y algunos valores bastante altos.

Si el histograma es asimétrico, positivo y no parece exponencial pura, la lognormal merece ser probada.

Ejemplo típico: tiempos de atención, duración de procesos y ciertas variables económicas. La mayoría de los clientes paga en 2 a 5 min, pero algunos demoran bastante más por un inconveniente.

Parámetros y estimación: primero se transforman los datos positivos con $y_i = \ln(x_i)$. Luego se calcula μL = media de los y_i y σL = desvío estándar de los y_i. Esos son los parámetros de la lognormal. En la escala original, la mediana es e^(μL).

Media original = e^(μL + σL² / 2) | Mediana = e^μL

DISTRIBUCIÓN GAMMA

La forma puede cambiar según sus parámetros, por eso se prueba contra los datos reales.

Es flexible y aparece mucho en modelos de tiempos de espera y procesos de servicio. Puede tomar distintas formas según sus parámetros. A veces se parece a una exponencial suavizada; otras veces tiene una sola cima y cola a la derecha.

Ejemplo típico: tiempos de proceso acumulados o duraciones con cierta variabilidad estructurada. Preparar un pedido requiere varias tareas positivas consecutivas; la suma de esas etapas puede parecer Gamma.

Parámetros y estimación: usando el método de los momentos, k (forma) ≈ $(\bar{x} / s)^2$ y θ (escala) ≈ $s^2 / \bar{x}$. La forma k indica si la curva es muy sesgada o si presenta un pico más marcado. Algunos programas usan tasa β = 1 / θ en lugar de escala; conviene revisar la convención de FlexSim.

Media = kθ | Varianza = kθ²

DISTRIBUCIÓN WEIBULL

Es muy usada en confiabilidad, desgaste, fallas y vida útil de componentes. También puede aparecer en tiempos de servicio.

Su curva puede cambiar bastante de forma según sus parámetros: desde una cola decreciente hasta una cima clara.

Ejemplo típico: tiempo hasta falla de una máquina o tiempo hasta reemplazo de un componente. El tiempo de uso de una impresora hasta que requiere mantenimiento o falla.

Parámetros y estimación: la Weibull tiene un parámetro de forma k y uno de escala η (eta). No hay una fórmula sencilla que funcione bien para todos los casos; normalmente se estiman mediante ajuste estadístico o con el módulo de ajuste de FlexSim. k cambia la forma de la curva y η establece la escala de los tiempos.

Media = $\eta \cdot \Gamma(1 + 1/k)$ | Γ es la función Gamma

3. ¿QUÉ ES LA BONDAD DE AJUSTE?

Bondad de ajuste significa medir qué tan cerca están los datos reales de una distribución propuesta. Es parecido a superponer la silueta de los datos sobre una curva: si la curva reproduce bien el centro, la dispersión y la cola, es una buena candidata; si se aleja mucho, conviene descartarla.

La prueba no elige por sí sola. Primero se mira el histograma y se entiende el proceso; luego se usa una prueba para respaldar o cuestionar esa hipótesis. Un p-value mayor que 0,05 significa que con esa muestra no hay evidencia suficiente para rechazar la distribución. No significa que quedó demostrada como la única verdadera.

La bondad de ajuste responde una pregunta concreta: ¿qué tan bien una distribución teórica representa a los datos observados? No basta con que la curva "se parezca". Hace falta medir la diferencia entre lo observado y lo esperado.

En simulación, la bondad de ajuste sirve para elegir una distribución de entrada con más fundamento. Si varias opciones parecen razonables, la prueba estadística ayuda a ordenar la decisión.

- Se compara una muestra real con una distribución propuesta.
- Se calcula una medida de diferencia o discrepancia.
- Si la diferencia es pequeña, la distribución puede aceptarse como candidata.
- Si la diferencia es grande, conviene descartarla.

Clave de modelado

En la práctica, dos distribuciones pueden verse parecidas. Por eso no conviene elegir solo por intuición visual. El gráfico sirve como filtro inicial, pero **después hay que revisar las pruebas de bondad de ajuste** y también el sentido del proceso.
La mejor distribución no siempre es la más compleja; muchas veces se elige la que ajusta bien y además tiene sentido para el fenómeno que se quiere representar.

Recordatorio del Eje Temático 2

Al estudiar **números pseudoaleatorios** se verificaba que una secuencia generada por computadora se comportara como una secuencia aleatoria. Para ello se analizaban dos propiedades: uniformidad e independencia.

Se presentaron las siguientes pruebas:

Prueba de promedios: verifica si el promedio de los números está cerca de 0,5.
Chi-cuadrado: divide el intervalo en grupos y compara cuántos números se observaron en cada grupo con cuántos deberían aparecer si la distribución fuera uniforme.
Kolmogorov-Smirnov (K-S): compara la distribución acumulada observada de los números con la acumulada teórica de la uniforme. No necesita agrupar los datos en intervalos.
Prueba de corridas arriba y debajo de la media: analiza la independencia. Busca detectar si hay patrones o repeticiones sospechosas en la secuencia.

En esta unidad se reutiliza una lógica parecida, pero cambia la pregunta. Ya no se evalúa si un generador produce números uniformes: se busca decidir si los datos reales de entrada pueden representarse con una distribución candidata.

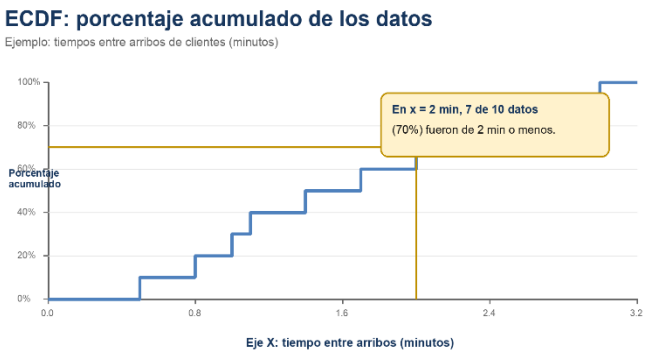
3.1. PRUEBA DE BONDAD DE AJUSTE K-S: KOLMOGOROV-SMIRNOV

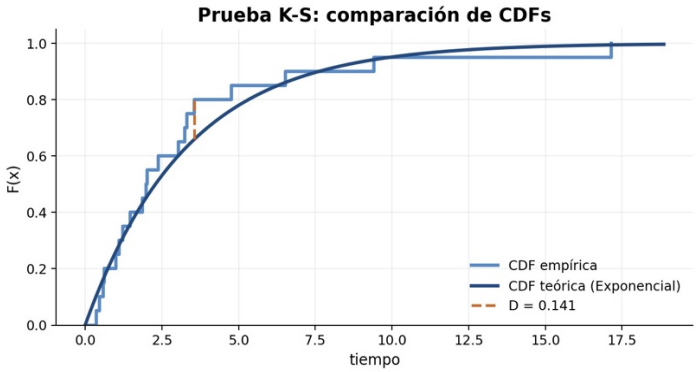
ECDF - FUNCIÓN DE DISTRIBUCIÓN EMPÍRICA ACUMULADA

ECDF significa Empirical Cumulative Distribution Function.

Es decir, que para cada valor x, muestra qué porcentaje de los datos fue menor o igual que x.

Gráficamente es una escalera porque cada dato nuevo hace subir el porcentaje acumulado.





La prueba K–S compara esta escalera real con la curva acumulada de una distribución propuesta. D es la mayor distancia vertical entre ambas. Cuanto menor es D, más parecidas son las dos curvas.

La prueba de Kolmogorov-Smirnov compara la función de distribución empírica de la muestra con la función de distribución teórica propuesta. En términos simples, mide la distancia máxima entre ambas curvas. Para K-S bilateral hay que medir la distancia en ambos lados de cada escalón, y tomar la máxima:

- Después del salto: $i/n - F(x_i)$

- Antes del salto: $F(x_i) - (i-1)/n$

En variables continuas es muy útil porque no necesita agrupar los datos en clases. Por eso, para ajuste de distribuciones, suele ser una de las pruebas más cómodas y didácticas.

3.2. PRUEBA DE BONDAD DE AJUSTE CHI-CUADRADO

1. Se agrupan los datos en intervalos.
2. Se calcula cuántos valores caen realmente en cada intervalo.
3. Se estima cuántos deberían caer según la distribución propuesta.



$$\chi^2 = \sum_{i=1}^{k} \frac{(O_i - E_i)^2}{E_i}$$

Los grados de libertad se calculan como $gl = k - 1 - p$ donde k es la cantidad de intervalos y p es la cantidad de parámetros estimados. Por ejemplo, para una Normal se estiman media y desvío: p = 2.

La prueba chi-cuadrado compara frecuencias observadas y esperadas dentro de intervalos. Es muy útil cuando se trabaja con datos agrupados o cuando se desea una explicación más intuitiva del ajuste.

A diferencia de K-S, necesita elegir clases o intervalos. El resultado depende de cómo se agrupen los datos, por lo que conviene usar intervalos razonables y no demasiado pequeños.

Ojo: hay que cuidar que los valores esperados no sean demasiado pequeños (no menores a 5); si lo son, conviene agrupar más. Luego se suman las diferencias cuadráticas ponderadas para obtener χ^2.

3.3. ¿CÓMO SE ELIGE LA DISTRIBUCIÓN?

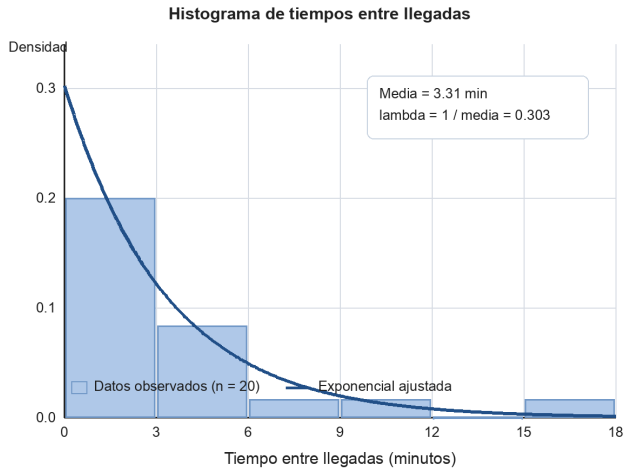
Las tablas estándar de K-S y de Chi-cuadrado suponen que la distribución teórica está completamente especificada de antemano.

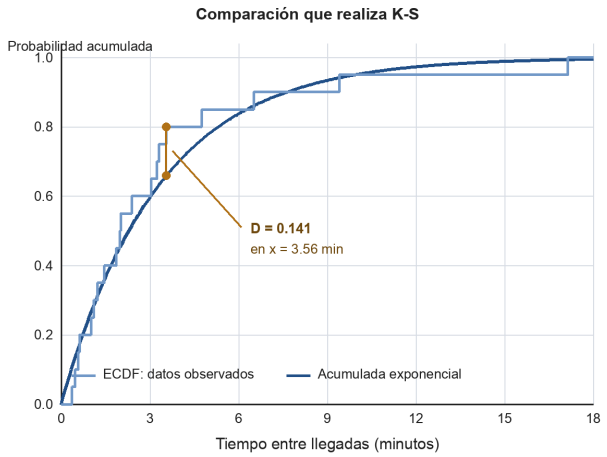
En simulación eso casi nunca ocurre: λ, μ o σ se estiman con los mismos datos que después se usan para probar el ajuste. Por eso, cuando el parámetro se estima con la misma muestra, **la prueba tiende a aceptar de más**. Por eso no conviene apoyarse únicamente en ella, lo correcto es combinar tres miradas: la forma visual del histograma, las medidas descriptivas y la bondad de ajuste. Cuando esas tres miradas coinciden, la decisión suele ser bastante sólida.

EJEMPLO 1 – PRUEBA K-S PARA TIEMPO ENTRE LLEGADAS

Supongamos que se midieron 20 tiempos entre llegadas de clientes en minutos. Al ordenar la muestra, se observa que la mayoría de los valores son pequeños, con algunos valores grandes al final. Esa forma ya hace pensar en una distribución asimétrica, posiblemente exponencial.

Dato ordenado	Valor
1	0.37
2	0.47
3	0.58
4	0.62
5	1.01
6	1.11
7	1.23
8	1.46
9	1.87
10	1.99
11	2.02
12	2.39
13	3.04
14	3.24
15	3.31
16	3.56
17	4.76
18	6.52
19	9.41
20	17.15





Tomamos como candidata la **distribución exponencial:**

H_0: los tiempos de llegadas siguen una distribución Exponencial

H_1: los tiempos de llegadas no siguen una distribución Exponencial

1. Ordenar los tiempos.
2. Calcular la media: $\bar{x} = 66{,}11/20 = 3{,}3055\ min$
3. Ajustar la exponencial.

- $\lambda = \frac{1}{\bar{x}} = 1 / 3{,}3055 = 0{,}3025$

4. Calcular la acumulada teórica para cada dato:

$$F(x) = 1 - e^{(-\lambda x)}$$

5. Calcular la diferencia máxima y comparar con el valor crítico de K-S:
   Para una muestra de 20 datos y un nivel de significancia de α = 0,05 la tabla de K-S indica: *D crítico=0,294*

i	x(i)	F Acumulada Empírica $F = i/n$	F Acumulada Teórica $F(x) = 1 - e^{(-\lambda x)}$	D después del salto: $i/n - F(x_i)$	D antes del salto: $F(x_i) - (i-1)/n$
1	0.37	0.05	0.11	0.06	0.11
2	0.47	0.10	0.13	0.03	0.08
3	0.58	0.15	0.16	0.01	0.06
4	0.62	0.20	0.17	0.03	0.02
5	1.01	0.25	0.26	0.01	0.06
6	1.11	0.30	0.29	0.01	0.04
7	1.23	0.35	0.31	0.04	0.01
8	1.46	0.40	0.36	0.04	0.01
9	1.87	0.45	0.43	0.02	0.03
10	1.99	0.50	0.45	0.05	0.00

11	2.02	0.55	0.46	0.09	0.04
12	2.39	0.60	0.51	0.09	0.04
13	3.04	0.65	0.60	0.05	0.00
14	3.24	0.70	0.62	0.08	0.03
15	3.31	0.75	0.63	0.12	0.07
16	3.56	0.80	0.66	0.14	0.09
17	4.76	0.85	0.76	0.09	0.04
18	6.52	0.90	0.86	0.04	0.01
19	9.41	0.95	0.94	0.01	0.04
20	17.15	1.00	0.99	0.01	0.04

Decisión final

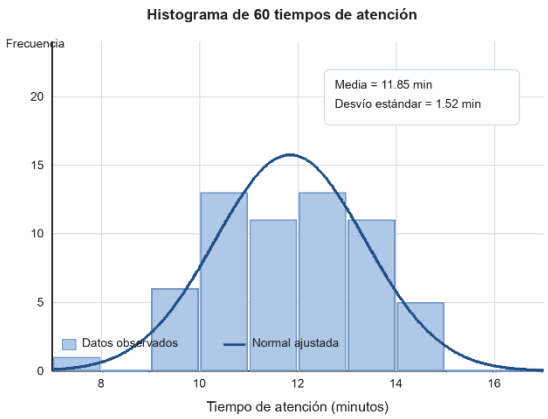
Si Dmax calculado < Dcrítico es decir 0,141 < 0,294

No se rechaza la hipótesis de que los tiempos entre llegadas siguen una distribución exponencial. Por lo tanto, la exponencial puede utilizarse como modelo de entrada para la simulación.

En este caso, la forma del histograma ya sugería una cola a la derecha. K-S acompaña esa intuición y no rechaza la exponencial. Por lo tanto, puede usarse la distribución exponencial en FlexSim para representar los tiempos entre llegadas de este proceso.

EJEMPLO 2 - PRUEBA CHI-CUADRADO PARA TIEMPOS DE ATENCIÓN

Se registraron 60 tiempos de atención en una caja de supermercado. El histograma muestra una forma aproximadamente simétrica, por lo que se propone como candidata una distribución Normal.



A partir de los datos se obtuvieron:

μ=11,85 min σ=1,52 min

Se plantea:

H_0: los tiempos de atención siguen una distribución Normal

H_1: los tiempos de atención no siguen una distribución Normal

Para aplicar Chi-cuadrado, los datos se agrupan en intervalos. Se incluyen las colas de la distribución y se verifica que todas las frecuencias esperadas sean mayores o iguales a 5.

Intervalo (minutos)	Frecuencia observada (O)	$z = \frac{x - \mu}{\sigma}$	Valor en tabla: $F(x) = P(Z \leq z)$	Frecuencia esperada (E) = $N\,[F(b_i) - F(a_i)]$	Aporte a χ^2 $(O - E)^2 / E$
X ≤ 10	7	— ; −1,217	0 ; 0,112	6,71	0,013
10 < X ≤ 11	13	−1,217 ; −0,559	0,112 ; 0,288	10,57	0,557
11 < X ≤ 12	11	−0,559 ; 0,099	0,288 ; 0,539	15,08	1,103
12 < X ≤ 13	13	0,099 ; 0,757	0,539 ; 0,775	14,16	0,095
X > 13	16	0,757 ; —	0,775 ; 1	13,48	0,471
Total	**60**			**60,00**	**2,239**

1. Calcular el valor de z para el lim. inferior y superior del rango.

$$z = \frac{x - \mu}{\sigma}$$

2. Buscar el valor de $F(z)$ en la tabla: *Si la tabla es sólo positiva y el valor de z es negativo, se utiliza la simetría de la distribución normal:* $F(-z) = 1 - F(z)$
3. Calcular la frecuencia esperada:

$$E_i = N\,[F(b_i) - F(a_i)]$$

4. Calcular el estadístico de Pearson

$$\chi^2 = \Sigma\,[(O_i - E_i)^2 / E_i] = 2{,}239$$

5. Determinar los grados de libertad: p = 2 por los parámetros μ y σ estimados. K=intervalos.

$$gl = k - p - 1 = 5 - 2 - 1 = 2$$

6. Buscar el valor crítico (α = 0,05) de la distribución

$$\chi^2\,crítico\;(gl = 2;\ \alpha = 0{,}05) = 5{,}991$$

7. Comparación y valor-p:

$$2{,}239 < 5{,}991 \quad y \quad p = P(\chi^2{}_2 \geq 2{,}239) \approx 0{,}326$$

Conclusión: Como $\chi^2 < \chi^2 crítico \;\; y \;\; p > 0{,}05$, no se rechaza H_0.

Los datos son compatibles con la Normal ajustada. Esto no demuestra normalidad; solo indica que no hay evidencia suficiente para descartarla.

3.4. CÓMO SE TRABAJA ESTO EN FLEXSIM

FlexSim permite analizar una muestra y comparar candidatos de distribución para ver cuál se ajusta mejor. El sistema generará luego nuevos tiempos que mantienen una forma parecida a la muestra.

Paso a paso en el software	
1. Preparar	Tener una columna limpia de datos en una sola unidad: por ejemplo, minutos entre arribos.
2. Cargar	Abrir Toolbox → Empirical Distribution y pegar/importar la columna de datos.
3. Mirar	Elegir Fitted Distribution para comparar curvas; revisar el histograma, las curvas y los parámetros.
4. Decidir	Elegir una candidata que tenga sentido. Si ninguna representa bien, elegir Continuous Empirical.
5. Aplicar arribos	En Source → Inter-Arrival Time, seleccionar la distribución o la Empirical Distribution.
6. Aplicar servicio	En Processor → Process Time, seleccionar la distribución o la Empirical Distribution.
7. Verificar	Generar muestras y revisar que su histograma se parezca al de los datos reales.

Tutorial simple:

https://youtu.be/TezghL9wtes?si=s_R5GpggdCVUa8wd

Importante: *No se necesita una distribución de salida. La salida de clientes es un resultado del modelo, producido por arribos, cola, recursos y tiempos de servicio.*

DISTRIBUCIÓN EMPÍRICA: CUANDO NINGUNA CURVA ALCANZA

Una distribución empírica no intenta obligar a los datos a ser Normal, Exponencial o Gamma. Usa directamente la forma de la muestra observada. En un supermercado, si los tiempos entre arribos reales fueron muchos de 1–2 min, algunos de 3–4 min y unos pocos muy largos, FlexSim genera nuevos tiempos con una forma parecida a esa muestra.

Se usa cuando varias curvas conocidas ajustan mal, cuando hay dos picos o cuando el proceso tiene una forma particular. No es una solución mágica: **necesita una muestra suficientemente grande, limpia y representativa**. Si los datos mezclan horarios pico y valle, primero hay que separarlos; si no, la distribución empírica copiaría una mezcla confusa.

RESUMEN UNIDAD 8 - ANÁLISIS DE DATOS DE ENTRADA

En esta unidad, los datos reales permiten elegir la distribución que mejor los representa. Luego FlexSim usa números pseudoaleatorios para sortear nuevos arribos y servicios que respetan esa distribución, siempre siguiendo la misma forma probabilística. Cada corrida representa un día posible del supermercado; al repetirlas se observa cómo cambian las colas y las esperas.

Errores frecuentes al trabajar con datos de entrada:

- Confundir instantes con duraciones.
- Cargar tiempos absolutos cuando se necesitan tiempos entre eventos.
- No limpiar valores mal cargados.
- Elegir una distribución solo por costumbre.
- Creer que el promedio alcanza para describir el proceso.
- Ignorar la variabilidad porque el modelo 'funciona'.

Checklist práctico antes de simular:

- ¿La variable está bien definida?
- ¿Los datos están en la unidad correcta?
- ¿Se revisaron outliers y faltantes?
- ¿Se calculó media, mediana, moda y desvío?
- ¿Se miró el histograma?
- ¿Se probaron varias distribuciones plausibles?
- ¿Se compararon los resultados con una prueba estadística?
- ¿La distribución elegida tiene sentido para el proceso?

Separación de datos:

En una mesa de ayuda suelen convivir distintos tipos de solicitudes. Algunas se resuelven muy rápido y otras consumen más tiempo. Si todos los casos se meten en una sola bolsa, la distribución puede quedar mezclada y perder sentido.

Por eso conviene separar por clase de servicio cuando el proceso lo requiera. Después se ajusta una distribución por tipo de caso y se evalúa cómo cambia el desempeño total del sistema.

- Separar si hay categorías diferentes.
- No mezclar procesos con comportamientos distintos.
- Revisar si cada clase necesita su propia distribución.

¿QUÉ MOSTRAR EN UN TRABAJO PRÁCTICO?

- Variable analizada y fuente de datos.
- Cantidad de observaciones y periodo de medición.
- Medidas descriptivas principales.
- Distribuciones probadas y criterios usados.
- Distribución elegida y parámetro(s) estimados.
- Prueba de bondad de ajuste utilizada.
- Interpretación práctica en el sistema real.

4. PLANEACIÓN TÁCTICA

Esta unidad continúa el recorrido iniciado con los datos de entrada: ahora el objetivo es ejecutar el modelo de manera confiable, interpretar sus resultados y convertirlos en una decisión aplicable. Una corrida es un futuro posible, no "la respuesta".

La planeación táctica define cuánto simular, desde cuándo medir y cuántas réplicas usar para obtener conclusiones con una precisión conocida.

4.1. EL PROBLEMA DE LA VARIABILIDAD

En una simulación hay variabilidad porque los arribos, los tiempos de atención, las fallas y otras entradas son aleatorias. Por eso, aun cuando el modelo y los parámetros no cambien, dos corridas pueden terminar con tiempos medios de espera distintos.

La variabilidad no es un error del software. Es parte del fenómeno que estamos representando. El error sería observar una sola corrida y concluir que ese valor es definitivo.

> Dos días pueden recibirse la misma cantidad de clientes. Sin embargo, si en uno de ellos llegan muchos clientes juntos, la espera puede ser mayor. El promedio de arribos no cuenta toda la historia: importa también la dispersión y la secuencia de los eventos.

Si $X_1, X_2, \ldots, X_n$ son los resultados de n réplicas independientes, la estimación del resultado medio es:

Medida	Fórmula	Lectura
Media de réplicas	$\bar{X} = (X_1 + X_2 + \ldots + X_n) / n$	Resultado medio estimado del sistema.
Desvío entre réplicas	$S = \sqrt{[\Sigma(X_i - \bar{X})^2 / (n - 1)]}$	Cuánto cambian los resultados de una corrida a otra.
Error estándar	$EE = S / \sqrt{n}$	Incertidumbre de la media estimada.

4.2. CONDICIONES INICIALES Y DE EQUILIBRIO

Al iniciar un modelo es habitual que las colas estén vacías y los recursos libres. Eso puede ser correcto para una tienda que abre, pero no para una guardia que ya estaba funcionando antes de que empecemos a observarla.

TIPOS DE SISTEMAS

Tipo	Ejemplo	Pregunta típica	Tratamiento
Terminante	Supermercado de 8 a 21 h	¿Cómo fue ese día?	El sistema se “vacía” o se reinicia naturalmente cada jornada. Puede haber cola final.
No terminante	Hospital 24/7 o servidor web	¿Cómo funciona en el largo plazo?	Funciona sin una finalización natural. Se requiere warm-up antes de medir la operación estable.

EL SESGO DE ARRANQUE

Si un sistema que normalmente tiene clientes en cola se inicia vacío, los primeros minutos parecerán demasiado tranquilos. Incluirlos en el promedio puede subestimar la espera real. Este efecto se llama **sesgo de inicialización** o problema transitorio inicial.

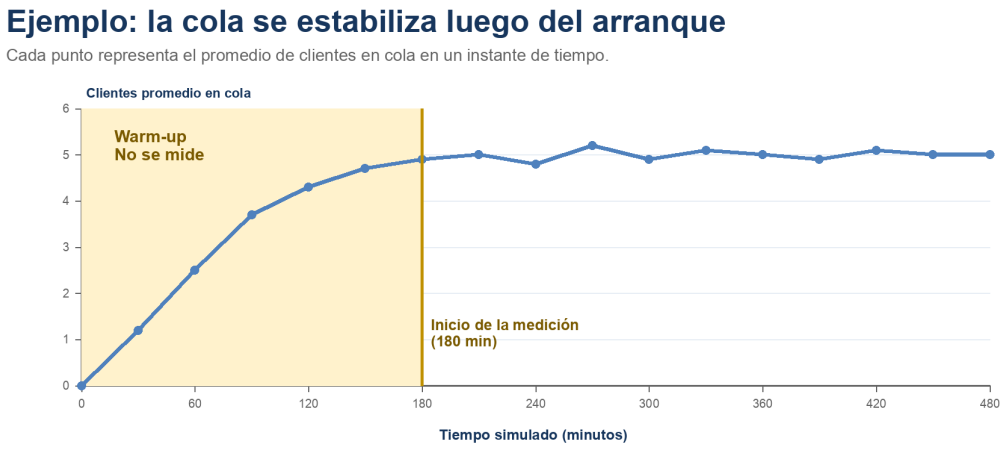


Figura. Ejemplo de warm-up.
Los datos antes de 180 min se descartan porque el sistema todavía se está estabilizando.

¿QUÉ ES EL WARM-UP?

El **warm-up** o período de calentamiento es el tiempo inicial de una simulación que se deja correr, pero cuyos resultados no se usan para calcular las medidas finales. Así se mide una operación más representativa.

Ejemplo: Se simula un hospital durante 30 días. Se decide usar los primeros 2 días como warm-up. Durante esos 2 días el modelo funciona normalmente, pero los resultados se miden desde el día 3 hasta el día 30.

Procedimiento gráfico sencillo:

- Ejecutar varias corridas piloto del mismo modelo.
- Registrar una medida en intervalos: por ejemplo, promedio de clientes en cola cada 30 minutos.
- Promediar las curvas o suavizarlas con una media móvil.
- Elegir como warm-up el momento a partir del cual la curva deja de mostrar una tendencia clara de arranque.

4.3. DETERMINACIÓN DEL TAMAÑO DE LA MUESTRA Y RÉPLICAS

En esta unidad, “tamaño de la muestra” se refiere a **cuántas réplicas independientes necesitamos**. No existe un número mágico universal: depende de cuánto varían los resultados y de cuánta precisión se necesita para tomar la decisión.

Con n réplicas independientes, un intervalo de confianza aproximado del 95% para la media es:

$$\bar{X} \pm t_{0{,}975,\, n-1} \frac{S}{\sqrt{n}}$$

X:media de los resultados obtenidos en las n réplicas.

S: desvío estándar entre los resultados de las réplicas.

n: cantidad de réplicas independientes.

$t0{,}975,\ n-1$: valor crítico de la distribución t de Student con n-1 grados de libertad.

Pero, en la práctica, FlexSim, Excel u otro software calcula el intervalo y su semiancho automáticamente. La recomendación práctica es buscar **un error relativo de hasta aproximadamente 15 %.**

Por ejemplo, si el resultado es: *12,0±1,2 minutos* significa que la estimación tiene una precisión de aproximadamente *±1,2 minutos*

Procedimiento práctico:

1. Elegir una precisión deseada.
   Ejemplo: "*quiero estimar la espera promedio con un error máximo de 0,5 minutos*" o "*acepto un error del 10 %".*
2. Hacer una corrida piloto de al menos 10 réplicas.
3. Obtener la media y el semiancho del intervalo de confianza con el software y comparar con el esperado.
4. Recalcular la cantidad de corridas necesarias: $n_{\text{nuevo}} \approx n_0 \left(\frac{H_0}{h}\right)^2$

Ejemplo: Se hicieron 10 réplicas y se obtuvo un intervalo con semiancho H_0=1 minuto. Se desea una precisión de 0,5 minutos.

$$n_{\text{nuevo}} \approx 10 \left(\frac{1}{0{,}5}\right)^2 = 40$$

Se deberían ejecutar aproximadamente **40 réplicas en total**, no 40 adicionales.

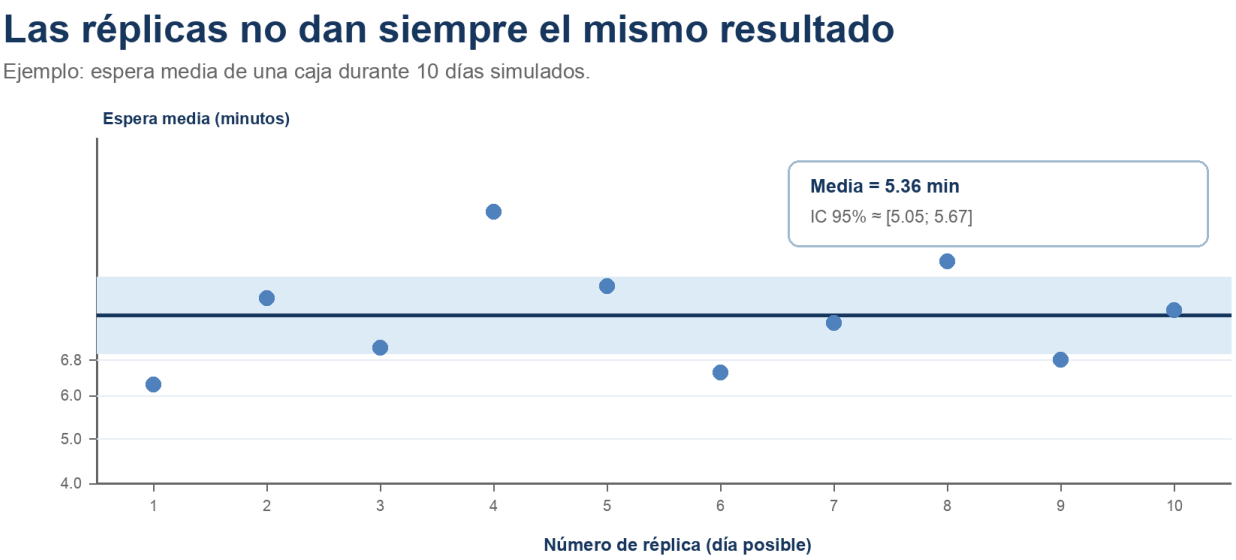


Figura. Eje X = réplica; eje Y = espera media en minutos.
La banda azul muestra el intervalo de confianza de la media de las 10 réplicas.

Una réplica representa una ejecución completa e independiente del escenario. Debe reiniciar el estado del sistema y las estadísticas, y continuar con una secuencia de números aleatorios independiente de la réplica anterior. No es lo mismo cortar una sola corrida larga en trozos: esos trozos pueden estar correlacionados.

Cómo decidir si ya son suficientes:

- Definir antes la precisión útil: por ejemplo, “estimar la espera media con un error no mayor a ±0,5 min”.
- Ejecutar un lote piloto de réplicas, calcular el intervalo y observar su semiamplitud.
- Si la semiamplitud supera lo aceptable, recalcular la cantidad de corridas necesarias y volver a ejecutar; si ya cumple, documentar el resultado.

4.4. REDUCCIÓN DE VARIANZA Y COMPARACIÓN DE ALTERNATIVAS

Reducir varianza significa **lograr una comparación más clara sin tener que multiplicar innecesariamente el número de réplicas**. No altera el sistema real ni "mejora" artificialmente los resultados: mejora la forma de experimentar con el modelo.

NÚMEROS ALEATORIOS COMUNES

Para comparar dos alternativas, se ejecuta la réplica 1 de ambas con la misma demanda aleatoria, la réplica 2 de ambas con otra demanda común, y así sucesivamente. Entonces se compara cada par. Si ambas alternativas responden de modo parecido a un día más demandante o más tranquilo, la diferencia entre ellas suele ser más estable.

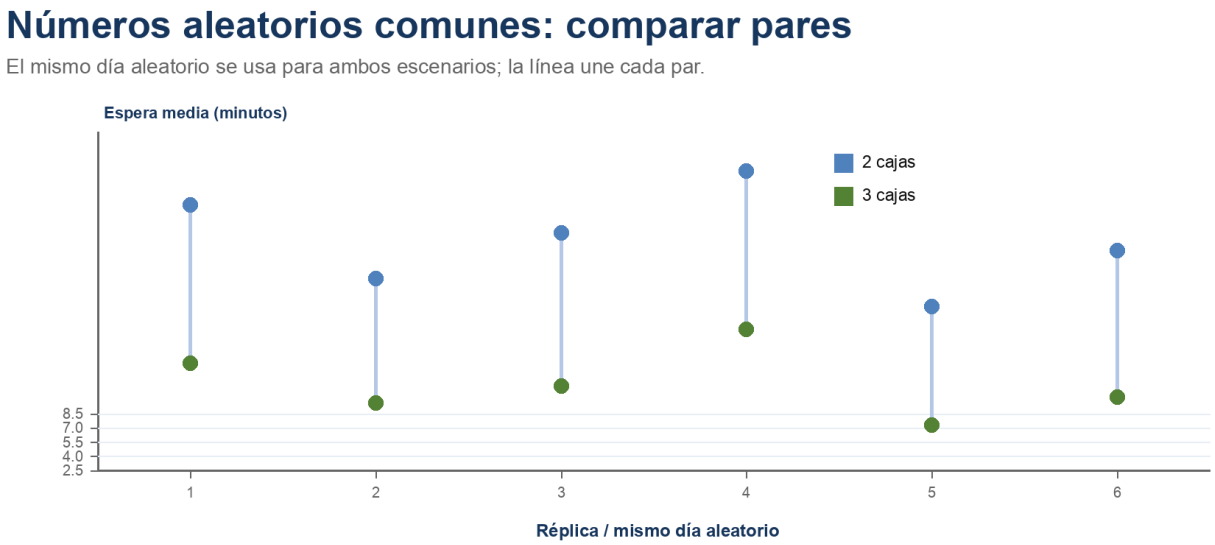


Figura. Cada línea vertical une el mismo día aleatorio para 2 y 3 cajas. Así la demanda del día no oculta tanto el efecto de agregar una caja.

Técnica	Idea simple	Uso recomendado en esta materia
Números aleatorios comunes	Comparar distintos escenarios bajo la misma demanda aleatoria.	Muy útil para comparar alternativas en FlexSim.
Más réplicas	Reducir incertidumbre por promedio.	Siempre que se requiera más precisión.
Variables antitéticas	Usar secuencias “opuestas” de aleatorios.	Mención conceptual: requiere más cuidado técnico.
Variables de control	Aprovechar una medida conocida y correlacionada.	Mención conceptual: se usa en análisis avanzado.

SIMULACIÓN EN FLEXSIM

El Experimenter en FlexSim permite definir escenarios, cantidad de réplicas, tiempo de parada y warm-up. Conviene preparar primero las medidas de desempeño que se van a comparar: espera media, cantidad atendida, utilización y tamaño medio de cola. Usar parámetros claros y conservar las mismas condiciones de base.

- Warmup Time indica cuándo se reinician las estadísticas
- Stop Time indica cuándo termina la réplica
- Replications per Scenario indica cuántos futuros aleatorios se ejecutan para cada alternativa

Paso	Qué hacer en FlexSim	Qué anotar en el informe
1. Definir escenarios	Crear, por ejemplo, “2 cajas” y “3 cajas” mediante parámetros.	Qué cambia y qué se mantiene igual.
2. Definir tiempo	Indicar Stop Time; agregar Warmup Time solo si el sistema lo necesita.	Unidad de tiempo y justificación.
3. Definir réplicas	Configurar Replications per Scenario.	Cantidad y criterio de precisión.
4. Guardar medidas	Seleccionar las estadísticas o dashboards relevantes por réplica.	Medidas de desempeño elegidas.
5. Ejecutar y revisar	Comparar promedios, intervalos y resultados individuales.	Conclusión y limitaciones.

EJEMPLO DE EXPERIMENTO

Dato que se decide antes de correr	Ejemplo para el supermercado
Objetivo	Comparar si una tercera caja reduce la espera en la franja de mayor demanda.
Escenarios	A: 2 cajas; B: 3 cajas. Las demás reglas se mantienen iguales.
Tiempo y warm-up	Jornada de 8 a 21 h; sin warm-up si se representa la apertura real.
Réplicas e informe	Empezar con un piloto, calcular el IC y aumentar hasta alcanzar la precisión definida.

5. VALIDACIÓN Y ANÁLISIS

Esta unidad continúa el recorrido iniciado con los datos de entrada: ahora el objetivo es ejecutar el modelo de manera confiable, interpretar sus resultados y convertirlos en una decisión aplicable.

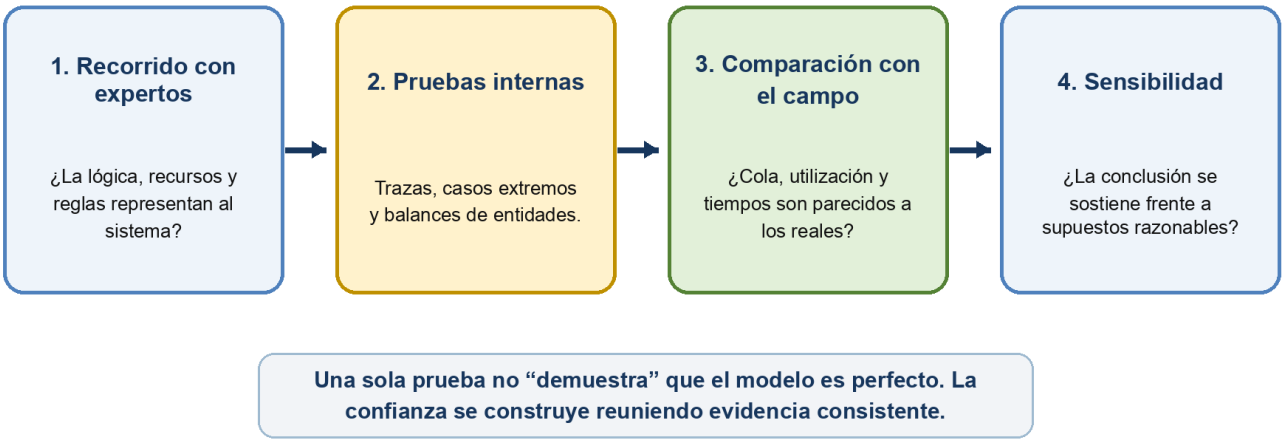
Un modelo es válido, para un objetivo concreto, **cuando existe evidencia suficiente de que representa el sistema con una precisión útil** para decidir.

Concepto	Pregunta que responde	Ejemplo en una caja de supermercado
Verificación	¿Construimos el modelo como lo describimos?	La regla FIFO, los horarios y la lógica de las cajas están programados correctamente.
Validación	¿El modelo representa razonablemente al sistema real para este objetivo?	La espera y la utilización simuladas se parecen a las observadas.
Credibilidad	¿Las personas que usarán el resultado confían y comprenden el estudio?	El encargado reconoce las reglas y acepta las conclusiones.

En el Eje 4 se trabajó la **verificación**: revisar que la lógica implementada no tenga errores.

Aquí se profundiza la **validación**: contrastar el modelo con el sistema y con el conocimiento de quienes trabajan en él.

Validación: evidencia que se complementa



5.1. VALIDACIÓN DEL MODELO

Conviene validar a medida que se construye el modelo, no al finalizar.

1. Definir el objetivo: por ejemplo, reducir la espera sin superar cierta utilización.
2. Documentar los supuestos: horarios, cantidad de cajas, prioridades, faltantes de personal y distribuciones.
3. Revisar el modelo conceptual con docentes, operadores o responsables del proceso.
4. Probar componentes de manera separada antes de analizar el sistema completo.
5. Comparar resultados simulados con datos reales cuando existan.
6. Registrar limitaciones: qué no está representado y para qué decisiones no debe usarse el modelo.

Un modelo puede ser válido para estimar la espera de clientes y no ser válido para diseñar la distribución física del local. La validez siempre está ligada al propósito y a las medidas de desempeño que se pretenden estudiar.

5.2. MÉTODOS SUBJETIVOS Y MÉTODOS OBJETIVOS

Los métodos subjetivos no son “menos serios”: usan conocimiento experto y observación.

Los métodos objetivos usan datos, gráficos y pruebas numéricas. En simulación se combinan porque un modelo puede coincidir numéricamente y, aun así, tener una regla importante mal representada.

Métodos subjetivos	Métodos objetivos
Recorrido estructurado del modelo con expertos del proceso.	Comparar media, desvío, percentiles y throughput con datos reales.
Revisión de animación: recorrido, colas, prioridades y recursos.	Pruebas de bondad de ajuste de los datos de entrada.
Entrevistas y revisión de reglas operativas. Preguntar qué excepciones importantes faltan	Intervalos de confianza y pruebas de hipótesis.
Juicio de coherencia: “si se duplica la demanda, ¿la cola debería crecer?”.	Pruebas de casos extremos, balances y trazas de eventos.

**** Throughput (rendimiento):*** *cantidad de elementos que un sistema logra completar o procesar en un período de tiempo. Ej: cantidad de clientes atendidos por hora. Cantidad de productos terminados por turno.*

5.3. PRUEBAS DE HIPÓTESIS APLICADAS A RESULTADOS

Una prueba de hipótesis ayuda a decidir si una diferencia observada puede atribuirse al azar de las réplicas o si es suficientemente consistente como para considerarla real dentro del experimento.

Elemento	Ejemplo: 2 cajas versus 3 cajas
Hipótesis nula H_0	La espera media es igual: $\mu_2$cajas − $\mu_3$cajas = 0.
Hipótesis alternativa H_1	La espera media con 3 cajas es menor: $\mu_2$cajas − $\mu_3$cajas > 0.
Nivel de significancia α	Por ejemplo 0,05: criterio de riesgo al rechazar H_0.
Evidencia	Diferencias por pares de réplicas, intervalo de confianza o p-value.
Decisión	Si el intervalo de la diferencia queda sobre 0, hay evidencia a favor de 3 cajas.

Lectura correcta de un p-value:

Un p-value pequeño indica que los datos observados serían poco compatibles con H_0. No dice que H_0 sea "falsa con un porcentaje exacto", ni mide por sí solo la importancia práctica de la mejora.

Además de la significancia, hay que mirar el tamaño del efecto: ahorrar 0,03 minutos quizás sea estadísticamente detectable, pero irrelevante para el negocio.

Error frecuente
Interpretar "no se rechaza H_0" como "los escenarios son iguales". Significa solamente que con las réplicas y la variabilidad disponibles no hubo evidencia suficiente para detectar una diferencia. Tal vez falten réplicas o la diferencia sea pequeña.

5.4. VERIFICACIÓN DE LA ESTRUCTURA INTERNA

La estructura interna se valida observando cómo funciona el modelo por dentro, no solo su resultado final. Es una forma de encontrar errores que podrían quedar ocultos detrás de un promedio aparentemente razonable.

Prueba	Cómo se realiza	Qué ayuda a detectar
Traza de una entidad	Seguir un cliente desde que llega hasta que sale.	Saltos de pasos, rutas incorrectas, tiempos mal asignados.
Balance de entidades	Entradas = salidas + presentes en el sistema.	Entidades duplicadas, perdidas o destruidas indebidamente.
Caso extremo	Poner 0 llegadas, una caja muy rápida o capacidad infinita.	Reglas invertidas, colas que no liberan o estadísticas incoherentes.
Prueba de sensibilidad lógica	Aumentar la demanda o reducir recursos.	Resultados con dirección contraria a la esperada.

5.5. PRUEBAS DE CAMPO

Cuando existe un sistema real, **las pruebas de campo comparan sus indicadores con los del modelo en condiciones equivalentes**. La clave es comparar el mismo período, los mismos horarios y las mismas categorías de clientes. No tiene sentido comparar una semana de promociones reales contra un día simulado sin promociones.

Comparación simple y útil:

Indicador	Campo	Modelo	Interpretación
Clientes atendidos por hora	29	28,5	Muy cercano; revisar varios días.
Espera media (min)	5,4	5,1	Diferencia moderada; revisar distribuciones y prioridades.
P95 de espera (min)	12,0	8,7	El modelo probablemente no representa bien los picos.
Utilización de cajas	83%	81%	Coherente; observar junto con espera.

No es obligatorio que cada cifra coincida exactamente. Se busca una diferencia aceptable para la decisión. Si la medida más importante muestra una discrepancia grande, no conviene avanzar a recomendaciones sin revisar el modelo.

Calibrar no es ocultar un problema: es ajustar parámetros inciertos dentro de rangos defendibles para mejorar la correspondencia con el sistema. No es cambiar valores libremente hasta que el gráfico "quede lindo". Todo cambio debe quedar documentado y debe mantener sentido operativo.

5.6. ANÁLISIS DE SENSIBILIDAD

El análisis de sensibilidad pregunta: "si este supuesto cambia dentro de un rango razonable, ¿cambia mi conclusión?". Sirve para saber dónde conviene invertir esfuerzo de medición y qué recomendaciones son robustas.

- Elegir un resultado de interés: espera, costo, utilización o nivel de servicio.
- Seleccionar factores inciertos o relevantes: demanda, tiempo de atención, cantidad de recursos, fallas.
- Definir valores bajo, base y alto que tengan sentido en el sistema real.
- Ejecutar réplicas suficientes para cada escenario y comparar intervalos, no solo una corrida.
- Explicar si la recomendación se mantiene o cambia con cada supuesto.

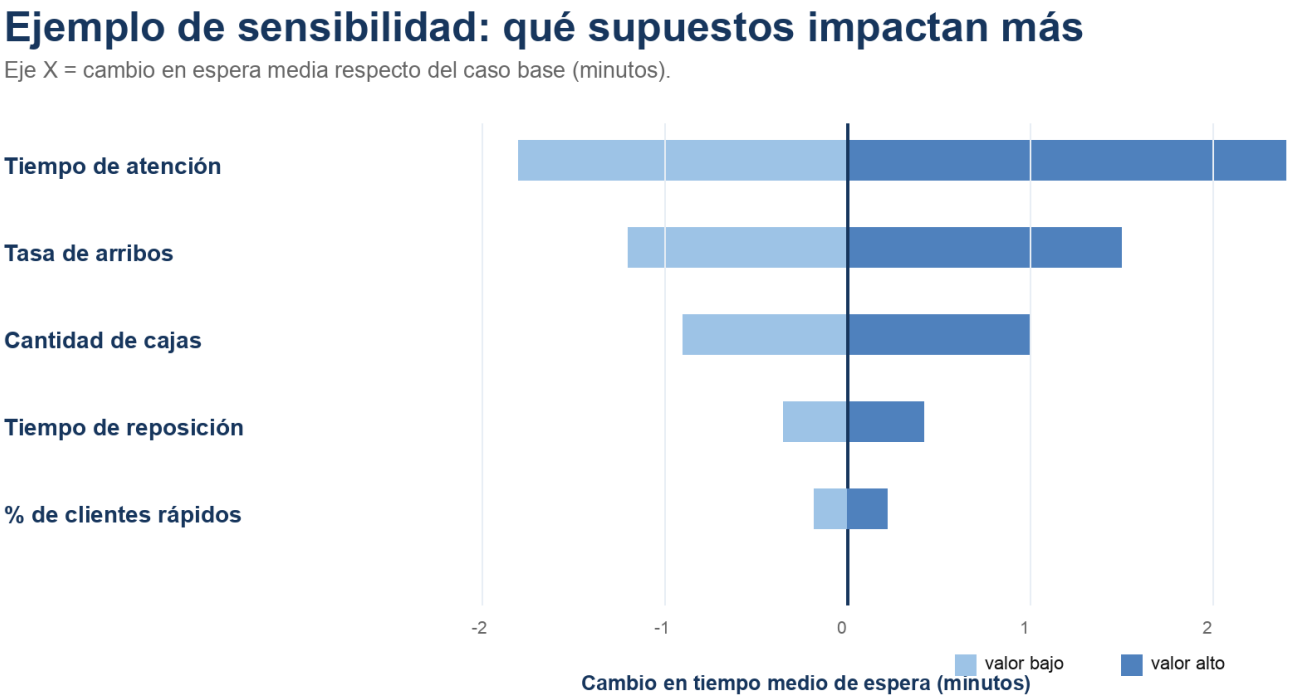


Figura. Diagrama tornado. Eje X = cambio en minutos de espera respecto del caso base. Las barras mayores identifican supuestos más influyentes.

INTERPRETACIÓN DEL EJEMPLO

En el gráfico, el tiempo de atención y la tasa de arribos son los factores que más cambian la espera. Por lo tanto, conviene medir mejor esas variables y evitar conclusiones fuertes si se conocen mal. En cambio, un factor de poco impacto puede modelarse de forma más simple sin afectar demasiado la decisión.

EN FLEXSIM: VALIDAR ANTES DE COMPARAR

Acción	Uso simple en FlexSim
Revisar recorrido	Ejecutar lento, pausar y seguir una entidad con la animación.
Probar límites	Cambiar temporalmente una capacidad o tiempo para verificar el comportamiento esperado.
Guardar resultados	Usar dashboards, Statistics Collector o tablas de salida por réplica.
Comparar escenarios	Configurar parámetros y escenarios en Experimenter; revisar valores individuales y promedios.
Exportar evidencia	Guardar gráficos o tablas y contrastarlos con una planilla de datos reales.

CHECKLIST DE VALIDACIÓN

- ¿El modelo fue verificado antes de validar sus resultados?
- ¿Los expertos revisaron supuestos y reglas?
- ¿Las medidas comparadas son las que importan para la decisión?
- ¿Se probaron trazas, balances y casos extremos?
- ¿Se comparó con datos de campo cuando fue posible?
- ¿Se analizó qué supuestos afectan más la conclusión?
- ¿Se documentaron limitaciones y alcance de la validez?

6. IMPLANTACIÓN

La salida de una simulación no debería ser “el escenario B es mejor” sin contexto. Una recomendación útil explica qué cambiar, cuánto se espera mejorar, qué costo o condición implica y con qué nivel de incertidumbre se obtuvo la conclusión.

Resultado de simulación	Traducción a decisión operativa
3 cajas reducen la espera media de 5,4 a 3,9 min.	Abrir una tercera caja en la franja de 18 a 21 h.
La utilización baja de 92% a 78%.	La capacidad adicional evita picos, no significa personal ocioso todo el día.
El P95 de espera sigue alto los sábados.	Complementar con caja rápida, reasignación o gestión de la demanda.
La mejora es sensible a la duración de atención.	Capacitar y simplificar el proceso de cobro; medir luego el efecto.

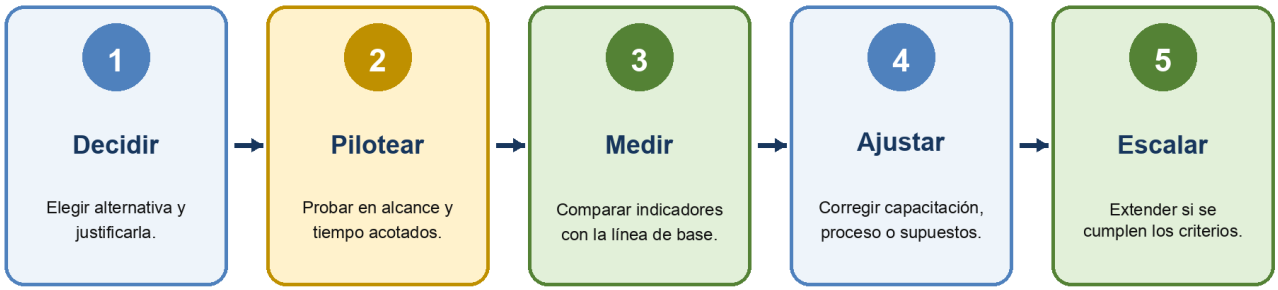
SIGNIFICANCIA PRÁCTICA

Una mejora debe ser importante para el objetivo real, no solo detectable estadísticamente. Reducir 0,1 minuto puede ser real pero no justificar el costo de contratar una persona. En cambio, evitar esperas de más de 15 minutos en hora pico puede ser valioso incluso si el promedio cambia poco.

6.1. PLAN DE IMPLANTACIÓN DE UNA MEJORA

La implantación transforma una alternativa simulada en un cambio real y controlado. Es preferible avanzar por etapas, en especial si la decisión afecta personas, turnos, costos o clientes.

De la simulación a la mejora real: ciclo de implantación



Resultado esperado: una mejora observable, medible y sostenible; no solamente una buena animación.

Componente	Pregunta a responder	Ejemplo: tercera caja
Objetivo	¿Qué se busca mejorar?	Bajar el P95 de espera en la franja 18–21 h.
Alcance	¿Dónde y cuándo se prueba?	Una sucursal, durante dos semanas.
Responsable	¿Quién coordina y decide?	Encargado de sucursal + jefe de personal.
Recursos	¿Qué se necesita?	Un cajero adicional y adaptación de turnos.
Riesgos	¿Qué podría fallar?	Ausentismo, caja sin demanda, desbalance en otras tareas.
Criterio de éxito	¿Cómo se decide seguir o corregir?	P95 ≤ 10 min sin aumentar costos fuera del límite definido.

6.2. PILOTO: EXPERIMENTAR EN EL SISTEMA REAL CON CUIDADO

Un piloto es una prueba limitada de la mejora antes de extenderla. No reemplaza la simulación: la complementa. La simulación permite explorar alternativas sin riesgo; el piloto verifica cómo funciona la alternativa elegida en el contexto real.

- Definir período y alcance acotados.
- Conservar una línea de base: medir antes de cambiar.
- Mantener registradas las condiciones especiales: promociones, feriados, ausencias o fallas.
- Explicar el cambio a las personas involucradas y recoger observaciones.
- Definir de antemano si el piloto se detiene, corrige o escala.

COMPARACIÓN ANTES Y DESPUÉS

Indicador	Línea de base	Piloto	Criterio
Espera media (min)	5,4	4,0	Mejorar al menos 1 min.
P95 de espera (min)	14,6	9,7	No superar 10 min.
Clientes atendidos/h	29	30	No disminuir.
Costo adicional por h	$0	$X	Dentro del presupuesto acordado.
Satisfacción del cliente	Encuesta base	Encuesta piloto	No disminuir.

No comparar solo promedios sin mirar las condiciones. Si durante el piloto hubo una demanda mucho menor, la mejora puede parecer mayor de lo que realmente es. Por eso importa registrar el contexto y, cuando sea posible, comparar franjas y días similares.

6.3. SEGUIMIENTO Y EVALUACIÓN POSTERIOR

Después de implantar, se verifica si el cambio se sostiene. El seguimiento permite separar una mejora real de un resultado transitorio y detectar efectos no previstos en otras partes del sistema.

Momento	Qué revisar	Decisión posible
Durante el piloto	Cumplimiento de procedimiento, incidencias y datos diarios.	Corregir la forma de aplicar la mejora.
Al finalizar	Indicadores versus criterios de éxito.	Escalar, ajustar o discontinuar.
A 1–3 meses	Sostenibilidad, costos y efectos secundarios.	Actualizar turnos, capacitación o el modelo.
Ante cambios relevantes	Nueva demanda, horarios, tecnología o reglas.	Revalidar el modelo antes de usarlo de nuevo.

INDICADORES QUE CONVIENE SEGUIR

- Nivel de servicio: espera media, percentil 95, porcentaje atendido antes de un límite.
- Capacidad: utilización, tiempo ocioso, cola máxima y throughput.
- Costo: horas de personal, horas extra, desperdicio o penalizaciones.
- Calidad y personas: errores, retrabajo, satisfacción de clientes y carga de trabajo.

6.4. COMUNICACIÓN DE RESULTADOS

Una buena presentación no oculta la incertidumbre ni abruma con todos los gráficos disponibles. Debe permitir que quien toma la decisión entienda el problema, la alternativa propuesta, la evidencia y las condiciones bajo las cuales se espera la mejora.

Parte del informe	Contenido mínimo
Problema y objetivo	Qué se quiere mejorar y por qué importa.
Modelo y alcance	Qué representa, datos usados y principales supuestos.
Experimento	Escenarios, tiempo de corrida, warm-up y réplicas.
Resultados	Promedios, intervalos y gráficos claros de las medidas importantes.
Recomendación	Cambio propuesto, beneficio esperado, costo y condiciones.
Plan y seguimiento	Piloto, responsables, indicadores, fecha de revisión y riesgos.
Limitaciones	Qué no se modeló y cuándo debe revisarse la conclusión.

No se debe presentar la animación como prueba suficiente ni prometer resultados exactos. Comunicar que la simulación aporta una estimación bajo supuestos explícitos y que la implantación se verifica con mediciones posteriores.

DOCUMENTACIÓN: EL MODELO COMO HERRAMIENTA QUE SE MANTIENE

Las distribuciones de entrada, los horarios, la demanda y las reglas del sistema pueden cambiar. Un modelo que fue válido en un momento puede requerir actualización. **Documentar los supuestos y guardar los experimentos facilita volver a usarlo con responsabilidad.**

- Guardar versión del modelo, fecha, datos de entrada y escenarios ejecutados.
- Registrar qué recomendación se aplicó y qué ocurrió en el sistema real.
- Actualizar parámetros cuando aparezcan datos nuevos o cambios relevantes.
- Repetir validación si el modelo se usa para una nueva decisión u otro alcance.

RESUMEN EJE TEMÁTICO 6: SUPERMERCADO

Unidad	Aplicación al caso
Unidad 8: datos de entrada	Se miden interarribos y tiempos de atención; se limpian los datos y se seleccionan distribuciones.
Unidad 9: planeación	Se definen jornada, réplicas, precisión e igualdad de condiciones entre “2 cajas” y “3 cajas”.
Unidad 10: validación	Se revisa la lógica, se comparan espera y throughput con la sucursal real y se hace sensibilidad.
Unidad 11: implantación	Se propone un piloto de tercera caja en hora pico, con indicadores y fecha de evaluación.

Simular no es “hacer correr un modelo”. Es transformar datos en un experimento, interpretar resultados con incertidumbre, validar el alcance de la conclusión y acompañar la mejora hasta que pueda observarse en el sistema real.

REFERENCIAS BIBLIOGRÁFICAS DEL EJE TEMÁTICO 6

- Law, A. M. (2015). Simulation Modeling and Analysis (5th ed.). McGraw-Hill Education. Capítulos 5, 6, 9, 10 y 11.
- Banks, J., Carson, J. S., Nelson, B. L. y Nicol, D. M. (2010). Discrete-Event System Simulation (5th ed.). Pearson.
- Sargent, R. G. (2013). Verification and Validation of Simulation Models. Journal of Simulation, 7, 12–24.
- Montgomery, D. C. y Runger, G. C. (2018). Applied Statistics and Probability for Engineers (7th ed.). Wiley.
- NIST/SEMATECH. e-Handbook of Statistical Methods. Secciones de intervalos de confianza, pruebas de hipótesis y análisis exploratorio.
- FlexSim Software Products, Inc. Documentation: Experimenter, Running Experiments y Model Repeatability.